

中图分类号：TP391

单位代号：10280

密 级：公开

学 号：23721373

上海大学



专业硕士学位论文

SHANGHAI UNIVERSITY
PROFESSIONAL MASTER'S
DISSERTATION

题 目	基于时空注意力机制的犯罪行为建模与预测研究
--------	-----------------------

作 者 赵宇辰

学科专业 电子信息

导 师 吴汉舟

完成日期 二〇二六年五月

上海大学工学专业硕士学位论文

基于时空注意力机制的犯罪行为建模
与预测研究

作者: 赵宇辰

学科专业: 电子信息

导师: 吴汉舟

通信与信息工程学院

上海大学

2026 年 5 月

A Dissertation Submitted to Shanghai University for the Degree
of Master in Engineering

**Research on Criminal Behavior
Modeling and Prediction Based on
Spatio-Temporal Attention Mechanism**

Candidate: Yuchen Zhao

Major: Electronic Information

Supervisor: Hanzhou Wu

School of Communication and Information Engineering

Shanghai University

May, 2026

摘 要

随着城市化进程的推进以及信息技术的快速发展，城市公共安全治理对犯罪风险预测提出了更高要求。犯罪行为在时间与空间维度上具有复杂的动态演化特征，对未来犯罪风险进行准确预测，对于优化警力资源配置和提升城市治理能力具有重要意义。然而，城市犯罪数据通常存在时空依赖性强、数据稀疏和分布不均衡等问题，现有方法在局部与全局依赖协同建模以及稀疏场景预测方面仍存在不足。为此，本文围绕城市犯罪预测中的时空建模与注意力机制展开研究，主要工作如下：

1) 针对现有方法难以同时刻画局部空间依赖与全局关联关系的问题，本文提出一种全局增强原型注意力网络模型。该方法首先通过嵌入层将原始犯罪计数映射到连续潜在空间，随后构建局部依赖建模模块，捕捉邻近区域、相邻时间片和犯罪类型之间的细粒度交互关系。在此基础上，引入原型感知的全局注意力机制，将细粒度时空特征聚合为可学习原型表示，从而建模跨区域、跨时间的长距离依赖关系。同时，设计全局-局部信息调制机制，实现局部细节与全局上下文的自适应融合。针对大量零值样本导致的预测偏置问题，本文提出两阶段预测策略，将犯罪发生概率预测与犯罪强度预测解耦。实验结果表明，该模型在多个评价指标上优于现有主流方法，尤其在低密度区域中表现出更高的预测精度和更强的鲁棒性。

2) 在上述研究基础上，本文进一步提出一种基于跨维度信息交互的深层注意力预测模型。针对现有方法难以充分刻画不同维度复杂依赖关系的问题，该模型首先利用局部特征提取模块获取空间-类型和时间-类型局部关联特征，为后续全局建模提供局部归纳偏置；随后引入卷积式位置编码层，将空间位置和时间顺序信息融入特征表示，并通过基于低秩投影的高效全局自注意力机制，在降低计算复杂度的同时捕捉跨区域、跨时间以及跨犯罪类型的长距离依赖关系。此外，本文设计上下文信息融合机制，利用局部信息对全局表示的重要性进行动态调制，并结合卷积前馈增强模块和可堆叠全局增强结构，逐层整合全局上下文与局部细节信息。实验结果表明，该模型在多个基准模型对比中取得更优表现，并在稀疏区域中有效降低预测误差，体现出较强的鲁棒性与泛化能力。

关键词：犯罪预测；注意力机制；原型学习；深度学习；城市计算

ABSTRACT

With the continuous advancement of urbanization and the rapid development of information technology, urban public safety governance has placed higher demands on crime risk prediction. Criminal activities exhibit complex dynamic patterns in both temporal and spatial dimensions. Accurate prediction of future crime risks is of great significance for optimizing police resource allocation and improving urban governance capacity. However, urban crime data usually suffer from strong spatio-temporal dependencies, high sparsity, and imbalanced distributions. Existing methods still have limitations in jointly modeling local and global dependencies and in improving prediction performance under sparse scenarios. Therefore, this thesis focuses on spatio-temporal modeling and attention mechanisms for urban crime prediction. The main work is summarized as follows:

1) To address the problem that existing methods have difficulty simultaneously capturing local spatial dependencies and global correlations, this thesis proposes a global-enhanced prototype attention network. The proposed method first maps raw crime counts into a continuous latent space through an embedding layer, and then constructs a local dependency modeling module to capture fine-grained interactions among neighboring regions, adjacent time steps, and crime categories. On this basis, a prototype-aware global attention mechanism is introduced to aggregate fine-grained spatio-temporal features into learnable prototype representations, thereby modeling long-range dependencies across regions and time periods. Meanwhile, a global-local information modulation mechanism is designed to adaptively fuse local details with global contextual information. To alleviate the prediction bias caused by a large number of zero-valued samples, a two-stage prediction strategy is further proposed to decouple crime occurrence probability prediction from crime intensity prediction. Experimental results show that the proposed model outperforms existing mainstream methods on multiple evaluation metrics, especially achieving higher prediction accuracy and stronger robustness in low-density regions.

2) Building upon the above research, this thesis further proposes a deep attention predic-

tion model based on cross-dimensional information interaction. To address the limitation of existing methods in fully characterizing complex dependencies across different dimensions, the model first employs a local feature extraction module to capture space-type and time-type local correlation features, providing local inductive bias for subsequent global modeling. Then, a convolutional position encoding layer is introduced to incorporate spatial location and temporal order information into feature representations. Based on a low-rank projection strategy, an efficient global self-attention mechanism is adopted to capture long-range dependencies across regions, time periods, and crime categories while reducing computational complexity. In addition, a contextual information fusion mechanism is designed to dynamically modulate the importance of global representations using local information. By further incorporating a convolutional feed-forward enhancement module and a stackable global enhancement structure, the model progressively integrates global context and local detailed information. Experimental results demonstrate that the proposed model achieves better performance than multiple baseline models and effectively reduces prediction errors in sparse regions, showing strong robustness and generalization ability.

Keywords: Crime prediction; Attention mechanism; Prototype learning; Deep learning; Urban computing

目 录

摘 要	I
ABSTRACT	III
第一章 绪论	1
1.1 研究目的及意义.....	1
1.2 国内外研究现状.....	3
1.2.1 基于统计与空间分析的犯罪预测	3
1.2.2 基于传统机器学习的犯罪预测	4
1.2.3 基于深度学习的犯罪预测.....	5
1.3 本文研究内容及结构安排.....	6
1.3.1 主要研究内容	6
1.3.2 结构安排	7
1.4 本章小结	8
第二章 相关技术介绍	9
2.1 犯罪预测基本概念	9
2.2 犯罪预测问题的分类	10
2.2.1 犯罪时空预测	10
2.2.2 犯罪类型预测	11
2.2.3 犯罪嫌疑人预测.....	12
2.3 犯罪预测问题的评价指标.....	13
2.4 神经网络模型	15
2.4.1 卷积神经网络	15
2.4.2 注意力神经网络.....	20
2.5 本章小结	23
第三章 基于原型注意力机制的犯罪时空预测模型	24
3.1 引言	24
3.2 算法设计	25

3.2.1	模型总体结构	25
3.2.2	嵌入层	26
3.2.3	局部依赖建模	27
3.2.4	全局依赖建模	29
3.2.5	全局-局部信息调制	31
3.2.6	两阶段犯罪预测机制	32
3.3	实验结果与分析	33
3.3.1	模型训练与优化	33
3.3.2	实验设置	35
3.3.3	模型性能分析	37
3.3.4	消融实验分析	39
3.4	本章小结	41
第四章	基于全局-局部信息增强的犯罪时空预测模型	42
4.1	引言	42
4.2	算法设计	43
4.2.1	模型总体架构	43
4.2.2	局部特征提取	45
4.2.3	全局信息增强	47
4.2.4	上下文信息融合	50
4.2.5	全局增强模块的堆叠结构	51
4.3	实验结果与分析	52
4.3.1	模型训练与优化	52
4.3.2	实验设置	53
4.3.3	模型性能分析	55
4.3.4	消融实验分析	57
4.4	本章小结	59
第五章	总结与展望	60
5.1	总结	60
5.2	展望	61

参考文献	63
攻读专业硕士学位期间取得的研究成果	70
致 谢	71

第一章 绪论

1.1 研究目的及意义

随着城市化进程的不断推进以及信息技术的快速发展，城市公共安全问题逐渐成为社会治理中的重要研究方向。近年来，人口规模的持续增长、城市空间结构的不断变化以及社会活动方式的多样化，使得城市犯罪问题呈现出更加复杂的发展趋势。犯罪行为不仅威胁居民的生命财产安全，还对社会稳定与城市治理产生重要影响。因此，如何通过科学方法对犯罪行为进行分析与预测，从而为公共安全管理提供有效的决策支持，成为智慧城市建设和社会治理领域的重要研究课题。

随着信息技术和数据采集技术的发展，城市中大量与犯罪相关的数据被不断记录和积累，例如报警记录、犯罪案件数据以及城市环境数据等。这些数据为犯罪行为分析提供了重要的数据基础。然而，犯罪数据通常具有复杂的时间变化规律和空间分布特征。从时间维度来看，犯罪事件往往在不同时间段呈现出明显的变化趋势，例如某些犯罪行为在夜间或节假日期间更容易发生。从空间维度来看，犯罪行为通常在城市特定区域呈现出明显的聚集现象^[1]，并且不同区域之间可能存在一定的关联关系。因此，如何从海量城市数据中挖掘犯罪行为的时空规律，并实现对未来犯罪风险的预测，成为犯罪数据分析研究中的重要问题^[2-3]。

早期的犯罪预测研究主要依赖统计学方法，例如时间序列分析、回归分析以及犯罪热点分析等。这类方法通过分析历史犯罪数据的分布规律，对犯罪行为的发生概率进行预测，在一定程度上为犯罪预测研究奠定了基础。然而，由于城市犯罪数据往往具有非线性特征、数据稀疏性以及复杂的时空依赖关系，传统统计方法在处理大规模城市犯罪数据时存在一定局限。例如，一些方法在建模空间关系时通常仅考虑相邻区域之间的简单关系，而难以刻画城市不同区域之间更加复杂的空间关联结构；同时，在时间建模方面，一些方法难以有效捕捉犯罪行为在长期和短期时间尺度上的动态变化规律。因此，仅依赖传统统计模型往往难以充分刻画犯罪行为复杂的时空演化规律^[4-5]。

随着大数据技术和人工智能技术的发展，研究人员开始将机器学习和深度学习方法应用于犯罪预测研究。例如，通过卷积神经网络（Convolutional Neural Network,

CNN)提取犯罪数据中的空间特征,通过循环神经网络(Recurrent Neural Network, RNN)或长短期记忆网络(Long Short-Term Memory Network, LSTM)建模时间序列特征,从而实现对犯罪行为时空变化规律的建模。深度学习模型能够通过多层网络结构自动提取数据特征,在处理复杂非线性数据方面具有明显优势,因此在犯罪预测领域逐渐受到广泛关注^[6-7]。

尽管深度学习方法在犯罪预测研究中取得了一定进展,但现有研究仍然存在一些不足。一方面,部分方法在建模空间关系时主要关注局部邻域信息,而忽略了城市不同区域之间可能存在的全局关联关系,这在一定程度上限制了模型对复杂空间结构的表达能力。另一方面,在时间建模过程中,不同时间段对犯罪预测任务的重要性可能存在明显差异,而传统模型通常难以自动识别这些关键时间特征^[8-9]。此外,犯罪行为往往受到多种因素的综合影响^[10-12],其时空分布模式具有高度复杂性,因此如何在模型中同时有效刻画空间依赖关系、时间依赖关系以及关键特征的重要性,仍然是当前犯罪预测研究中的重要问题。

针对上述问题,本文以城市犯罪数据为研究对象,围绕犯罪行为的时空特征建模展开研究,旨在构建一种能够有效融合空间特征与时间特征的犯罪预测模型。通过引入注意力机制,使模型能够自动识别对预测任务具有重要影响的关键时空特征,从而提升模型对复杂时空关系的表达能力。本文在分析犯罪数据时空特征的基础上,构建基于深度学习的时空预测模型,并进一步设计融合注意力机制的时空建模方法,以实现对城市犯罪行为更加准确和稳定的预测。

本研究的开展不仅具有重要的理论意义,同时也具有较强的实际应用价值。从理论角度来看,本文通过引入注意力机制对犯罪行为的时空特征进行建模,为复杂时空数据分析提供了一种新的研究思路。从实践角度来看,通过对犯罪高发区域和高发时间段进行预测,可以为公安机关合理配置警力资源提供重要参考,提高巡逻与防控工作的针对性和效率。同时,通过对犯罪行为时空演化规律的分析,也能够为城市公共安全治理提供科学依据。因此,开展基于时空注意力机制的犯罪行为建模与预测研究,对于推动人工智能技术在公共安全领域的应用以及提升城市社会治理能力具有重要意义。

1.2 国内外研究现状

随着城市犯罪数据规模的不断扩大以及人工智能技术的快速发展，犯罪预测逐渐成为数据挖掘与智慧城市研究的重要方向。国内外学者围绕犯罪行为的空间分布特征、时间演化规律以及影响因素展开了大量研究，并提出了多种犯罪预测方法。总体来看，现有研究主要分为三类：基于统计与空间分析的方法、基于机器学习的方法以及基于深度学习的时空预测方法。

1.2.1 基于统计与空间分析的犯罪预测

早期的犯罪预测研究主要依赖统计学方法以及地理信息系统（Geographic Information System, GIS）的分析方法。这类方法通常从历史犯罪数据出发，通过对犯罪发生频次、区域分布特征以及时间变化趋势的统计分析，识别犯罪热点区域并预测未来一定时期内的犯罪风险。从研究范式上看，统计方法侧重于从数据中提取总体规律与影响因素，例如分析犯罪率与人口结构、经济状况、社会环境等变量之间的关系；而空间分析方法则更关注犯罪事件在地理空间中的分布特征及其聚集现象，借助地图可视化、空间自相关分析和热点探测等手段揭示犯罪活动的区域差异与空间关联。相较于后续复杂的深度学习模型，这类方法具有模型结构清晰、可解释性较强、实现成本较低等特点，在犯罪预测研究发展的早期阶段发挥了重要作用，也为后续更加复杂的时空建模方法奠定了基础。

在犯罪学理论方面，Brantingham 提出的环境犯罪学理论（Environmental Criminology）指出^[13]，犯罪行为与个体对生活环境的感知空间密切相关。随后 Felson 和 Clarke 提出的犯罪模式理论（Crime Pattern Theory）以及常规活动理论（Routine Activity Theory）进一步强调了犯罪行为在时间与空间上的规律性特征。这些理论为犯罪预测研究提供了重要的理论基础。

在方法层面，研究者通常利用回归模型、贝叶斯模型以及时间序列分析方法对犯罪数据进行建模。例如，Bunnin 等^[14]提出了一种贝叶斯分层模型，通过整合目击者证词、法证证据等多种信息源，来系统评估刑事调查中犯罪嫌疑人的涉案概率。Rodrigues 等^[15]提出一种基于泊松点过程的条件方法，将空间-时间点过程预测问题转化为分类问题，并使用机器学习算法从数据中学习行为模式，最后根据分类问题的结果进行空间-时间风险预测。Mohler 等^[16]提出了基于自激点过程（Self-exciting Point Process）的犯罪建模方法，将犯罪事件建模为具有触发效应的时空过程，有效

刻画了犯罪的时空传播特性。刘^[17]运用线性回归模型分析了人口结构、经济指标、教育水平等社会因素与犯罪率之间的定量关系，初步验证了利用宏观社会变量进行犯罪趋势预测的可行性。李^[18]使用灰色系统模型对全国的杀人案和抢劫案案件数进行了预测，能够有效抑制数据中的干扰因素，从而提高预测精度。

总体来看，基于统计与空间分析的方法能够从宏观层面揭示犯罪活动的时空分布规律，并在一定程度上实现对犯罪趋势的刻画与预测。然而，这类方法通常依赖于人工设计特征或较强的先验假设，对于犯罪数据中复杂的非线性关系和高维时空依赖结构建模能力有限。随着数据规模的扩大以及计算能力的提升，研究者开始尝试引入能够自动学习特征表示的传统机器学习方法，以进一步提升犯罪预测的准确性与适应性。

1.2.2 基于传统机器学习的犯罪预测

随着犯罪数据规模的不断增长以及数据驱动分析方法的发展，研究者开始将传统机器学习方法引入犯罪预测任务。与早期主要依赖统计分析和空间可视化的研究不同，传统机器学习方法更加关注从多源数据中提取特征，并利用模型对犯罪发生规律进行学习。常见方法包括支持向量机（Support Vector Machine, SVM）、决策树（Decision Tree）、随机森林（Random Forest）、朴素贝叶斯（Naive Bayes）以及人工神经网络（Artificial Neural Network, ANN）等。这类方法通常将历史犯罪记录、人口统计信息、社会经济指标、地理环境特征以及时间属性等作为输入，通过训练分类或回归模型来预测特定区域在未来时段内的犯罪风险。相较于传统统计方法，机器学习方法在非线性关系建模、特征综合利用以及预测精度方面具有一定优势，因此逐渐成为犯罪预测研究中的重要技术路径。

Berk等^[19]针对缓刑与假释人员群体中的谋杀风险预测问题，提出了基于统计学习的方法，通过构建风险预测模型对高风险个体进行识别，实现了对严重暴力犯罪行为的有效预测，并验证了数据驱动方法在高风险决策场景中的应用价值。Wang等^[20]利用 Twitter 数据分析社会事件，并结合支持向量机模型识别潜在犯罪热点区域。此外，Aziz等^[21]对比了多种回归分析模型，指出预测地区盗窃犯罪数量的回归模型中，基于随机森林回归的模型相对最佳。孙等^[22]提出一种改进的随机森林方式提高了预测精度。陈等^[23]基于时空分析方法构建犯罪热点预测模型，实现了对犯罪高发区域的预测。

然而,传统机器学习方法通常仍较为依赖人工特征工程,其预测效果在很大程度上依赖特征设计的质量与完整性。对于犯罪数据中普遍存在的高维性、稀疏性以及复杂的时空耦合关系,这类方法往往难以自动挖掘更深层次的表示特征,也较难充分刻画长程时空依赖和动态演化规律。随着大规模时空数据的不断积累以及深度学习技术的发展,研究者开始尝试利用具有自动特征学习能力的深度模型进一步提升犯罪预测的表现,从而推动相关研究逐步迈向基于深度学习的犯罪预测阶段。

1.2.3 基于深度学习的犯罪预测

自2010年代以来,随着深度学习技术的快速发展,越来越多的研究开始尝试利用深度神经网络对犯罪行为进行建模。相较于传统统计方法和机器学习方法,深度学习能够通过多层非线性结构自动挖掘数据中的潜在表示特征,减少对人工特征工程的依赖,因此在复杂模式识别与时空序列建模任务中展现出较强优势。犯罪数据通常具有显著的空间相关性、时间动态性以及多因素耦合特征,不同区域之间的犯罪活动可能存在空间传导效应,不同时段之间也往往表现出周期性、突发性和长期演化并存的复杂规律。深度学习方法凭借其在高维数据表示学习和非线性关系建模方面的能力,为刻画这类复杂时空依赖关系提供了新的技术路径。尤其是在大规模城市感知数据、人口流动数据、社会环境数据以及历史犯罪记录不断积累的背景下,基于深度学习的犯罪预测逐渐成为该领域的重要研究方向。

Feng等^[24]通过提取两个时间关系中链接的犯罪行为来构建犯罪行为图,并采用图卷积网络作为法律收费预测的预测器,在裁判文书中的语义信息的有效性表现出领先水平。Azeez等^[25]通过融合多源数据特征与多种模型优势,显著提升了预测精度和鲁棒性。然而,许多早期深度学习方法在建模过程中并未同时考虑犯罪数据的时间和空间特征。近年来,研究者逐渐开始关注时空信息融合问题^[26-28]。犯罪行为本质上具有明显的时空演化特征,预测任务可被视为一种典型的时空序列预测问题。这与计算机视觉领域中的视频序列在时空维度上的变化具有一定相似性。因此视频预测领域提出的一系列时空建模方法为犯罪预测模型的设计提供了重要启示。

随着Transformer的影响不断扩大,其变体模型^[29]也逐渐被引入计算机视觉领域。与此同时,卷积神经网络在计算机视觉任务中具有独特优势。卷积神经网络通过多种卷积核提取多维特征信息,在图像识别、目标分割以及视频预测等任务中表现出较强的性能。例如,Xie等^[30]通过结合卷积神经网络的空间建模能力与长

短期记忆网络的时间建模能力，实现了对车辆轨迹的有效预测。Jiang等^[31]提出了OM-CNN模型，该模型显式融合了目标的静态属性和动态运动特征，并利用两层ConvLSTM网络生成像素级显著性图，捕捉显著性在时间维度上的平滑变化过程。

然而，卷积神经网络的感受野通常较为有限。为了获得全局感受野，需要不断堆叠卷积层，这会随着图像或视频分辨率的提高显著增加网络深度和计算复杂度。此外，长短期记忆网络在建模长距离依赖关系方面能力有限，并且在处理可变长度序列时灵活性不足。相比之下，Transformer模型在捕获全局空间信息以及建模长序列依赖关系方面具有明显优势，因此在视频和图像数据建模中表现出更强的能力^[32-33]。例如，Neimark等^[34]提出了一种基于Transformer的视频建模架构VTN，能够直接对视频序列信息进行建模。Girdhar等^[35]提出Anticipative Video Transformer，通过端到端注意力结构对已观测视频内容进行建模，用于预测未来动作状态。此外，还有一些研究提出了结合卷积神经网络与Transformer的混合预测方法，以充分发挥两种模型的优势^[36-37]。

总体来看，基于深度学习的犯罪预测方法在自动特征学习、复杂非线性关系建模以及时空依赖刻画方面展现出了明显优势，为提升犯罪预测的准确性和鲁棒性提供了新的思路。然而，现有研究在全局与局部时空关联的协同建模、稀疏场景下的稳定预测以及多维特征的有效融合等方面仍存在一定不足。基于此，如何构建能够更充分挖掘犯罪数据时空演化规律、兼顾模型表达能力与预测性能的深度学习框架，仍然是当前犯罪预测研究中值得进一步探索的重要方向。

1.3 本文研究内容及结构安排

1.3.1 主要研究内容

现有的犯罪预测方法大多依赖统计模型或传统机器学习方法，通过分析历史犯罪数据的统计特征来预测未来犯罪风险。虽然这些方法在一定程度上能够揭示犯罪行为的时间变化规律或空间分布特征，但在处理复杂的城市犯罪数据时仍存在明显局限。例如，当犯罪发生在特定区域时（例如抢劫或盗窃），类似的犯罪更有可能蔓延到邻近地区。换句话说，邻近地区的犯罪模式往往表现出很强的相似性。此外，即使地理上遥远但功能相似的地区（如同一城市内的多个街区）也可能会显示出类似的犯罪模式。同时犯罪倾向于表现出一定的时间相关性。例如，盗窃更可能发生

在工作时间，当个人通常不在家时。因此，时间依赖性，特别是时间轴上两个遥远的时间点之间的相关性，也是犯罪预测模型中的一个重要考虑因素。

不同类型犯罪的发生往往是相互关联的。例如，当发生盗窃时，如果犯罪者在行为过程中被逮捕，事件可能升级为抢劫甚至杀人。同样，出于实际原因，如果商店被抢劫，由于执法部门的干预或采取了更多的预防措施，在短时间内再次发生抢劫的可能性可能会降低，因此，犯罪类型之间的影响也应该被考虑在内。

1.3.2 结构安排

第一章为绪论。本章主要介绍研究背景与研究意义，分析国内外相关研究现状，明确本文的研究问题与研究思路，并对全文的研究内容及结构安排进行总体说明。

第二章为相关理论与方法基础。本章主要介绍犯罪预测任务的基本概念与问题分类，包括犯罪类型预测、犯罪嫌疑人预测以及犯罪时空预测等内容；随后阐述犯罪数据的评价指标体系，并对卷积神经网络及相关深度学习模型进行介绍，为后续模型构建提供理论基础。

第三章为基于全局一局部调制的原型注意力犯罪预测模型。本章针对传统方法难以同时建模局部空间依赖与全局关联的问题，构建融合局部建模与全局原型注意力机制的预测模型，并设计两阶段预测策略，以提升模型在复杂时空数据下的表达能力与预测精度。




图 1.1 论文各章节内容及其逻辑关系

Figure 1.1 Logical relationship among chapters of the thesis

第四章为基于时空特征融合的深度学习预测模型。本章在前述研究基础上，进一步探索犯罪数据中时空特征的交互机制，通过引入模块化和全局-局部信息融合机

制，从而增强模型对复杂时空依赖关系的刻画能力。

第五章为总结与展望。本章对本文的主要研究工作进行总结，分析所提出方法的优势与不足，并对未来在犯罪预测及相关领域的研究方向进行展望。

1.4 本章小结

本章围绕城市犯罪预测问题，对研究背景、研究意义及国内外研究现状进行了系统梳理。首先，从城市化进程加快与公共安全需求提升的现实背景出发，分析了犯罪行为在时间与空间维度上所呈现的复杂动态特征，指出利用数据驱动方法开展犯罪预测研究在智慧城市建设中的重要价值。其次，对现有研究进行了分类综述，分别从统计与空间分析方法、机器学习方法以及深度学习方法三个方面总结了国内外研究进展。分析表明，传统方法在刻画复杂时空依赖关系方面存在明显不足，而深度学习方法虽在一定程度上提升了建模能力，但在全局与局部依赖建模以及关键特征选择等方面仍有改进空间。

在此基础上，本章进一步明确了犯罪预测任务中存在的 key 问题，包括空间关联关系建模不足、时间依赖刻画不充分以及多维特征交互机制缺失等。针对上述问题，本文提出了以时空建模与注意力机制为核心的研究思路，并对全文的主要研究内容与结构安排进行了系统说明。

综上，本章为后续章节的研究奠定了理论基础与问题背景，为深入开展基于深度学习的犯罪时空预测模型研究提供了必要的理论支撑与研究方向。

第二章 相关技术介绍

2.1 犯罪预测基本概念

城市犯罪预测（Crime Prediction）是指利用历史犯罪数据及相关辅助信息，对未来一定时间范围内特定区域的犯罪发生情况进行分析与预测的过程。该任务作为智慧城市与公共安全领域的重要研究方向，旨在为警力部署、风险预警以及城市治理决策提供数据驱动的支持，从而提升社会安全水平与治理效率。

从数据属性来看，犯罪数据通常具有显著的时空特征。一方面，犯罪事件在空间上往往呈现出明显的聚集性，即某些区域在特定时间段内更容易成为犯罪高发区域，这种现象通常被称为“犯罪热点”。另一方面，犯罪行为在时间维度上也表现出一定的周期性与连续性，例如不同时间段（如工作日与周末、白天与夜晚）可能对应不同的犯罪发生模式。因此，犯罪预测任务需要同时刻画空间依赖关系与时间动态变化规律。

进一步来看，犯罪行为不仅受到地理位置与时间因素的影响，还与多种社会环境因素密切相关。例如人口密度、经济发展水平、交通状况以及社会活动模式等，都可能对犯罪发生产生重要影响。这些复杂因素相互作用，使得犯罪数据呈现出高度非线性与不确定性的特征，从而增加了预测建模的难度。此外，犯罪数据通常具有高度稀疏性与分布不均衡的特点。在大多数时间与空间区域内，犯罪事件往往较少甚至不存在，而少数区域则可能集中出现大量犯罪记录。这种“长尾分布”现象使得模型在学习过程中容易受到零值数据的干扰，从而影响预测精度。因此，如何有效建模稀疏数据并提升模型对少量关键事件的感知能力，是犯罪预测研究中的重要问题之一。

从任务形式上来看，犯罪预测可以被视为一种典型的时空序列预测问题，核心目标是基于历史观测数据学习潜在的演化规律，并对未来状态进行估计。与传统时间序列预测相比，犯罪预测不仅需要考虑时间依赖，还需同时处理空间关联以及不同类型犯罪之间的交互关系，这使得问题更加复杂。

综上所述，城市犯罪预测任务具有多维度、多因素耦合的特点，其关键在于如何在统一框架下有效建模时间、空间及语义信息之间的复杂关系。为此，研究者通

常需要结合统计方法、机器学习以及深度学习等多种技术手段，以实现了对犯罪行为的准确建模与预测。后续章节将在此基础上进一步介绍基于栅格数据的具体建模方式与实现方法。

2.2 犯罪预测问题的分类

犯罪预测并不是单一形式的预测任务，而是可以根据预测对象和应用目标的不同划分为多种类型。从研究内容来看，犯罪预测既可以关注犯罪事件在时间和空间上的分布变化，也可以关注未来可能发生的犯罪类型，还可以面向具体个体或群体开展风险评估。不同类型的犯罪预测任务在数据表示、建模目标和实际应用场景方面存在一定差异，因此需要采用相应的建模方法进行分析。根据现有研究，犯罪预测通常可以分为犯罪时空预测、犯罪类型预测和犯罪嫌疑人预测等几类。其中，犯罪时空预测主要关注犯罪事件在何时、何地发生；犯罪类型预测侧重于判断未来可能发生的犯罪类别；犯罪嫌疑人预测则更关注潜在高风险个体或相关嫌疑人的识别与评估。下面分别对上述几类典型犯罪预测任务进行介绍。

2.2.1 犯罪时空预测

从研究视角来看，传统犯罪预测方法通常分别从时间或空间单一维度对犯罪行为进行分析。例如，犯罪数量预测主要从时间序列角度出发，关注犯罪事件随时间的变化趋势；而犯罪热点预测则侧重于空间维度，分析犯罪在不同区域的分布特征。这类方法在一定程度上能够刻画犯罪行为的局部规律，但往往将时间与空间因素割裂开来，分别作为独立变量进行建模，难以全面反映犯罪行为的复杂演化过程。

实际上，犯罪行为并非孤立发生，而是具有显著的时空相关性。一方面，历史犯罪事件在时间上会对未来犯罪产生持续影响，表现出一定的延续性与周期性；另一方面，在空间上，邻近区域之间往往存在相互影响关系，甚至在更大尺度范围内也可能存在潜在的关联模式。因此，在实际警务应用中，综合考虑时间与空间依赖关系，对犯罪行为进行联合建模的时空预测方法显得尤为重要。随着大数据技术与人工智能方法的发展，越来越多的研究开始利用机器学习与深度学习方法开展犯罪时空预测。根据输入数据表示形式的不同，现有研究通常可以分为基于栅格数据的犯罪时空预测方法与基于非栅格数据的犯罪时空预测方法。

基于栅格数据的犯罪时空预测方法通过将研究区域划分为规则网格单元，将犯

罪事件映射至对应网格中，从而构建结构化的时空数据表示形式。该方法能够将复杂的空间问题转化为统一的离散建模问题，并结合滑动时间窗口提取时间序列特征，从而利用机器学习或深度学习模型对犯罪行为的时空变化规律进行建模与预测。由于其结构清晰且易于与深度学习方法结合，该类方法在当前研究中被广泛采用。

基于非栅格数据的犯罪时空预测方法则直接利用轨迹数据、不规则空间单元以及路网结构等信息，对犯罪事件进行建模。这类方法通常通过构建图结构或网络结构来刻画空间单元之间的拓扑关系，并结合时间序列分析对犯罪行为进行预测。虽然该类方法在空间表达上具有一定灵活性，但其建模过程较为复杂，对数据质量与计算资源要求较高，在实际应用中仍存在一定限制。

犯罪时空预测通过统一建模时间与空间信息，能够更全面地刻画犯罪行为的演化规律，已成为当前犯罪预测研究的重要方向之一。本文在此基础上，采用基于栅格数据的建模方式，并进一步引入注意力机制对复杂时空依赖关系进行建模，以提升预测性能。

2.2.2 犯罪类型预测

犯罪类型预测（Crime Type Prediction）是指基于历史犯罪数据及相关特征信息，对未来可能发生的犯罪类型进行分类判别的过程。该任务通常被建模为一个多分类问题，其目标在于识别不同犯罪行为之间的差异，从而为公安机关制定差异化防控策略提供支持。通过对犯罪类型的准确预测，可以实现更为精细化的警力部署与资源配置，在提升执法效率的同时降低犯罪发生率。

从方法角度来看，犯罪类型预测主要依赖于各类分类算法，涵盖传统机器学习方法与深度学习方法两大类。传统方法中，常用算法包括 K 近邻（K-Nearest Neighbor, KNN）、决策树、随机森林、朴素贝叶斯以及支持向量机（Support Vector Machine, SVM）等。这类方法通常具有实现简单、计算效率较高等特点，适用于中小规模数据集或特征结构相对简单的场景。其中，随机森林作为一种典型的集成学习方法，通过构建多棵决策树并进行结果集成，能够有效捕捉犯罪数据中的复杂非线性关系，在实际应用中表现出较好的分类性能。

相比之下，朴素贝叶斯模型基于特征条件独立性假设，具有计算效率高、实现简便的优势，但在实际犯罪数据中，由于特征之间往往存在相关性，其预测性能可能受到一定限制。支持向量机则通过构建最优分类超平面实现类别划分，在小样本

数据场景下具有较强的泛化能力，但其性能依赖于核函数选择与参数调优，在处理高维复杂数据时存在一定局限。

随着深度学习技术的发展，越来越多的研究开始采用神经网络模型进行犯罪类型预测。与传统方法相比，深度学习模型能够通过多层网络结构自动提取高阶特征，有效刻画犯罪数据中的复杂模式关系，尤其在处理多维数据与时间序列数据时表现出较强优势。然而，这类方法通常对数据规模和计算资源要求较高，在实际应用中需要结合具体场景进行权衡。

犯罪类型预测方法的选择需要综合考虑数据规模、特征类型以及计算资源等因素。传统机器学习方法在效率与可解释性方面具有优势，而深度学习方法在复杂模式建模方面表现更为突出。未来研究可进一步探索多模型融合与特征协同建模方法，以提升预测精度与泛化能力，从而为智能警务决策提供更加可靠的技术支撑。

2.2.3 犯罪嫌疑人预测

犯罪行为的实施主体为个体，因此在犯罪预测研究中，对犯罪嫌疑人或潜在高风险人群进行预测具有重要意义。犯罪嫌疑人预测是指基于历史犯罪记录、个体特征及相关社会属性数据，对潜在犯罪个体或特定事件中可能涉及的嫌疑人群体进行识别与评估的过程。该任务在刑事侦查与社会治理中具有重要应用价值，可为公安机关提供决策支持，例如辅助筛选重点关注对象、提升案件侦破效率以及制定针对性的预防措施。

根据数据来源与特征形式的不同，犯罪嫌疑人预测通常可以分为基于结构化特征的数据分析方法，以及基于非结构化数据（如文本、图像等）的预测方法。其中，结构化数据主要包括个体历史犯罪记录、人口学特征及行为模式等信息，而非结构化数据则涉及案件文本描述、人脸图像及视频监控数据等。不同数据类型对应不同的建模方法，共同构成了犯罪嫌疑人预测的多模态研究框架。在具体研究中，累犯预测（Recidivism Prediction）是犯罪嫌疑人预测的重要分支，核心目标是评估个体再次犯罪的可能性。已有研究表明，具有犯罪记录的个体再次犯罪的概率显著高于普通人群，因此对累犯风险的预测具有重要现实意义。早期研究多采用统计模型对假释或再犯风险进行评估，例如基于回归分析或生存分析的方法对个体再犯概率进行建模。随后，研究者提出“分裂人口”模型等改进方法，通过区分高风险群体与一般人群，提高预测结果的准确性。

随着机器学习技术的发展,越来越多的研究开始采用数据驱动方法进行累犯预测。例如,随机森林、支持向量机以及梯度提升方法等被广泛用于构建个体风险评估模型,通过综合利用多维特征对再犯概率进行预测。这些方法在处理非线性关系和高维数据方面具有一定优势,但其性能往往依赖于特征工程质量与模型参数设置。近年来,深度学习方法在犯罪嫌疑人预测领域逐渐受到关注。相关研究表明,神经网络模型能够从大规模数据中自动提取潜在特征,从而提升预测性能。同时,一些新方法结合聚类分析与可解释性技术,对犯罪人群进行细粒度划分,并提高模型的透明性与公平性。然而,深度学习模型通常具有较高的计算复杂度,并在实际应用中面临可解释性与公平性等问题,这在司法场景中尤为关键。

犯罪嫌疑人预测融合了传统统计方法与现代机器学习技术,在个体风险评估与犯罪预防中具有重要作用。但由于犯罪行为受多种复杂因素影响,现有方法在数据质量、模型泛化能力以及结果解释性方面仍存在挑战。未来研究可进一步结合多源数据与可解释人工智能方法,提升模型的可靠性与应用价值,从而更好地服务于实际警务决策。

2.3 犯罪预测问题的评价指标

在犯罪预测任务中,评价指标用于衡量模型预测结果与真实观测值之间的差异,是判断模型性能优劣的重要依据。由于本文主要关注犯罪数量及其时空分布的预测问题,该类任务通常被建模为回归问题,因此往往在任务中多采用误差类指标对预测精度进行评估。

(1) 均方误差 (Mean Squared Error, MSE) 均方误差用于度量预测值与真实值之间误差平方的平均水平,其定义为:

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (2.1)$$

其中, y_i 表示真实值, $\hat{y}_i$ 表示预测值, n 为样本数量。MSE 对较大的预测误差具有更高的惩罚作用,因此在评估模型对异常波动的拟合能力时具有重要意义。

(2) 均方根误差 (Root Mean Squared Error, RMSE) 均方根误差是在 MSE 基础

上进行平方根变换得到，其表达式为：

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (2.2)$$

RMSE 与原始数据具有相同量纲，便于直观理解预测误差的实际大小。相较于 MSE，RMSE 经过平方根处理后能够将误差尺度还原到原始变量的量纲上，因此在结果解释时更加直观。同时较大的预测偏差会对最终结果产生更明显的影响，因此该指标对异常高值或犯罪高发区域的预测误差较为敏感。

(3) 平均绝对误差 (Mean Absolute Error, MAE) 平均绝对误差表示预测值与真实值之间绝对偏差的平均值，其定义为：

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (2.3)$$

MAE 对异常值不够敏感，能够较为稳定地反映模型在整体样本上的平均预测误差水平，因此是衡量模型总体预测性能的重要指标。与平方误差类指标相比，MAE 采用误差绝对值进行度量，不会因为少量较大偏差样本而被过度放大，因此更适合用于评估模型在大多数常规样本上的平均表现。通过该指标，可以直观刻画预测值与真实值之间的平均偏离程度，从而为不同模型之间的性能比较提供清晰依据。

(4) 平均绝对百分比误差 (Mean Absolute Percentage Error, MAPE) 平均绝对百分比误差用于衡量预测误差相对于真实值的比例，其定义如下：

$$\text{MAPE} = \frac{100}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \quad (2.4)$$

MAPE 以相对误差的形式对预测结果进行度量，能够以百分比形式直观反映预测值与真实值之间的偏差程度，因此在不同数据规模、不同量纲或不同类别之间具有较好的可比性。相较于绝对误差类指标，MAPE 更有利于从相对偏差的角度评估模型性能，能够更加清晰地体现模型在不同样本条件下的误差分布情况。在犯罪预测任务中，由于不同区域、不同时段以及不同犯罪类型之间的数值范围往往存在明显差异，采用 MAPE 能够在一定程度上减弱绝对数值尺度差异对评价结果的影响，从而为模型预测效果的横向比较提供更加统一的参考依据。与此同时，当真实值较小时，MAPE 对误差变化会表现出更强的响应特征，因此该指标能够从另一个侧面反映模型在低值样本上的预测表现，使评价结果更加全面。

综上所述，不同评价指标在衡量模型性能时各有侧重：**MSE** 和 **RMSE** 更关注较大误差，对极端值较为敏感；**MAE** 能够反映整体误差水平；**MAPE** 则提供了相对误差的衡量方式。在实际犯罪预测任务中，通常结合多种指标进行综合评估，以全面反映模型在不同场景下的预测能力。同时，针对犯罪数据稀疏性和分布不均衡的特点，部分研究还引入加权误差或分区域评估方法，进一步提升评价结果的可靠性。

2.4 神经网络模型

神经网络模型是深度学习方法的重要基础，核心思想是通过多层非线性映射从数据中自动学习特征表示，从而实现对复杂模式关系的建模。与传统人工特征构造方法相比，神经网络能够在训练过程中逐层提取低层到高层的特征信息，在图像识别、自然语言处理、时间序列预测及时空数据分析等任务中得到了广泛应用。对于城市犯罪预测任务而言，犯罪数据通常具有明显的时空依赖性、非线性变化特征以及分布不均衡等特点，因此需要借助具有较强表示学习能力的神经网络模型对其进行建模。本节将重点介绍卷积神经网络和注意力神经网络的基本原理，为后续章节中局部特征提取、全局依赖建模以及时空特征融合方法的设计提供理论基础。

2.4.1 卷积神经网络

卷积神经网络（Convolutional Neural Network, CNN）作为深度学习领域的重要基础模型之一，是一种专门用于处理网格结构数据的前馈神经网络，在图像识别、语音处理及自然语言处理等领域得到了广泛应用。卷积神经网络的核心思想在于利用局部连接与权值共享机制，有效降低模型参数规模并提升特征提取能力。具体而言，卷积神经网络通过卷积操作对输入数据进行局部加权计算。对于输入特征图，卷积核在其上滑动，并在局部感受野内执行加权求和运算，从而生成新的特征图。该过程可以表示为输入与卷积核之间的内积运算。通过设置多个卷积核，模型能够提取不同类型的局部特征，如边缘、纹理及形状等，从而形成多通道特征表示。

在网络结构上，卷积神经网络通常由输入层、卷积层、池化层以及输出层构成，并可结合激活函数层、归一化层及全连接层等组成完整模型。卷积层主要负责特征提取，通过局部感受野逐层扩大，使网络能够从低层的局部特征逐步学习到高层的全局语义信息。池化层则通过对特征图进行下采样，降低空间维度，减少参数数量，同时提升模型对平移变化的鲁棒性。常见的池化方式包括最大池化与平均池化，其

本质是在局部区域内进行特征聚合。

此外，为增强模型的非线性表达能力，卷积神经网络通常在卷积层之后引入激活函数，以实现复杂函数的拟合。在训练过程中，归一化层被广泛应用于稳定特征分布，加速模型收敛并缓解梯度消失问题。同时，为进一步防止过拟合，常采用 Dropout 等正则化技术，通过随机丢弃部分神经元来提升模型泛化能力。卷积操作通常涉及步长与填充等参数。其中，步长控制卷积核滑动的步幅，从而影响输出特征图的尺寸；填充则用于在输入边界补零，以保持特征图尺寸或减少边界信息损失。通过合理设置这些参数，可以在特征提取能力与计算效率之间取得平衡。

卷积层是卷积神经网络中最关键的组成部分，其主要任务是从输入数据中挖掘局部模式并形成更高层次的特征表示。在该过程中，卷积核作为一组可训练参数，会在输入特征图上按照一定规则逐位置滑动，并对当前局部区域执行加权求和运算，最终输出新的特征响应。由于卷积操作仅作用于局部邻域，网络能够在保留空间结构信息的同时，有针对性地提取局部相关特征。

卷积层的性能通常受多个因素影响，其中较为重要的包括卷积核大小、步长以及填充策略。卷积核大小决定了每次感知输入区域的范围，较小的卷积核有助于捕捉精细局部信息，而较大的卷积核则能够覆盖更宽的上下文区域。步长用于控制卷积核每次移动的距离，其取值越大，输出特征图的尺寸通常越小，对应的计算量也会降低。填充操作则是在输入特征图边界处补充额外数值，常见方式为零填充，其作用在于缓解边缘信息在卷积过程中被过度削弱的问题，同时还能在一定程度上调节输出特征图的尺寸。




图 2.1 卷积核原理图

Figure 2.1 Schematic diagram of convolution kernel

以图 2.1 所示的卷积运算为例，若输入特征图尺寸为 3×3 ，卷积核尺寸同样为 3×3 ，卷积步长设置为 1，输入边界无零填充，则卷积核从输入左上角位置开始移动。每到一个位置时，取出与卷积核对应的局部区域，与卷积核各元素之间进行逐项乘积计算，再将所有结果相加，并结合偏置项得到当前位置的输出值。随着卷积核在整幅输入特征图上的遍历，所有位置对应的结果共同构成最终输出特征图。通过堆叠多个卷积层，网络可以逐步从底层边缘或纹理等简单特征过渡到更高层次的抽象语义表示。

池化层通常设置在卷积层之后，其主要作用是对特征图进行压缩和整合，从而降低后续计算复杂度，并增强模型对局部扰动的适应能力。与卷积层侧重于特征提取不同，池化层更强调对已有特征进行筛选和概括。通过在局部窗口内对特征值进行聚合，池化操作能够保留关键响应，同时减少冗余信息。常见的池化方式主要包括最大池化和平均池化。最大池化倾向于保留局部区域内响应最强的特征值，因此更适合突出显著特征；平均池化则通过求取局部区域的均值来反映整体分布特征，使输出结果更加平滑。在实际应用中，池化层不仅能够有效缩小特征图尺寸，还可以在在一定程度上提升网络对平移、噪声以及细微形变的鲁棒性。因此，池化层在控制模型规模和增强特征稳定性方面发挥着重要作用。




图 2.2 池化原理图

Figure 2.2 Schematic diagram of pooling

如图 2.2 所示，池化操作以输入特征图中的局部区域作为处理单元，并按照预设窗口大小和步长逐步滑动，对窗口内的特征值进行聚合计算，从而生成尺寸更小

的输出特征图。图中给出了一个典型的 4×4 输入特征图，并采用 2×2 的池化窗口、步长为2进行下采样处理。池化窗口首先作用于左上角区域。若采用最大池化，则输出该区域中的最大值 3；若采用平均池化，则输出区域内元素的平均值 1.5。随后池化窗口按照步长向右和向下依次移动，对其余局部区域重复相同操作，最终得到右侧所示的输出结果。对于最大池化而言，各窗口对应输出值分别为 3、6、5 和 3，因此形成新的 2×2 特征图；对于平均池化，各窗口输出结果分别为 1.5、3.5、2.25 和 1.5。通过这一过程，原始特征图由 4×4 压缩为 2×2 ，在显著降低数据维度和计算量的同时，仍能够保留局部区域中的主要信息。由此可见，最大池化更侧重于突出显著响应特征，而平均池化更强调整体统计特征，两者在实际任务中可根据具体需求进行选择。




图 2.3 常见激活函数图像

Figure 2.3 Images of common activation functions

若网络仅由线性运算构成，则无论堆叠多少层，其整体表达能力仍然有限，难以拟合复杂的非线性映射关系。为此，卷积神经网络通常在卷积运算之后引入激活函数，以增强模型的非线性建模能力。激活函数能够对卷积层输出进行非线性变换，使网络具备学习复杂特征关系的能力。在实际模型中，ReLU 函数是最常见的一类激活函数。该函数在输入大于 0 时保持原值，在输入小于等于 0 时输出为 0，具有

计算简单、收敛速度较快等优点。通过在网络中加入激活函数，模型不仅能够提升特征表达的丰富性，还可以在在一定程度上缓解传统激活函数容易出现的梯度衰减问题。如图 2.3 所示，除 ReLU 外，LeakyReLU、Sigmoid 和 Tanh 等函数在不同任务中也具有一定应用价值，但从实际计算效率和模型训练稳定性来看，ReLU 及其变体通常更为常用。

随着网络层数的不断加深，深度神经网络虽然能够学习到更加抽象和复杂的特征表示，但其训练难度也会随之增加。在前向传播过程中，前一层网络参数的更新会导致后一层接收到的输入特征分布不断变化，使得模型需要持续适应新的数据分布。这种现象会在一定程度上影响网络的稳定训练，表现为收敛速度变慢、梯度传播不稳定、参数更新震荡等问题。尤其是在深层网络中，不同层之间的特征分布差异可能逐渐累积，从而进一步增加模型优化的难度。因此，如何保持中间特征分布的相对稳定，是深度神经网络训练中的一个重要问题。归一化层的引入，正是为了解决深层网络训练过程中容易出现的收敛缓慢、梯度不稳定等问题。其基本思想是对中间特征进行标准化处理，使其分布保持在相对稳定的范围内，从而改善网络的训练效果。Batch Normalization 是卷积神经网络中应用最广泛的归一化方法之一。该方法通常对一个批次中的特征进行归一化，然后再引入可学习的缩放和平移参数，以保留模型的表达灵活性。通过这种方式，网络在训练过程中能够减轻内部特征分布变化带来的不利影响，提高参数更新的稳定性，并加快模型收敛速度。此外，归一化层在一定程度上还具有正则化效果，有助于提升模型的泛化性能。




图 2.4 全连接原理图

Figure 2.4 Schematic diagram of fully connected layer

全连接层通常位于卷积神经网络的后端，其作用是对前面各层提取到的高维特征进行综合映射，并输出最终结果。在卷积层和池化层完成局部特征提取与压缩之后，网络会将得到的特征图展开为一维向量，并输入到全连接层中。由于全连接层中的每个神经元都与前一层的所有神经元相连接，因此其具有较强的全局信息整合能力。如图 2.4 所示，在分类任务中，全连接层通常用于将前面学习到的抽象特征映射到具体类别空间，并结合 Softmax 等函数输出各类别的概率分布；在回归任务中，则可直接输出连续值预测结果。需要注意的是，全连接层参数数量通常较多，若网络规模较大而样本数量有限，则容易出现过拟合现象。因此，在实际设计中，常常结合 Dropout 等正则化方法共同使用，以提高模型的稳定性和泛化能力。

2.4.2 注意力神经网络

注意力机制（Attention Mechanism）最初广泛应用于自然语言处理领域，核心思想是模拟人类在处理复杂信息时“关注关键部分、弱化次要信息”的认知过程。与传统神经网络对所有输入特征进行均匀处理不同，注意力机制能够根据当前任务目标，为不同位置、不同维度或不同时刻的特征分配不同权重，从而突出对预测结果更为重要的信息。由于其具有较强的特征筛选与依赖建模能力，注意力机制现已被广泛应用于图像识别、机器翻译、视频分析及时空预测等任务中。从本质上看，注意力机制是一种基于相关性度量的动态加权方法。对于输入特征序列，模型首先根据当前任务构建查询（Query）、键（Key）和值（Value）三类表示，然后通过计算查询与键之间的相似性，衡量不同输入特征对当前输出的重要程度，并将该相似性归一化为注意力权重，最终对值向量进行加权求和，得到聚合后的特征表示。其计算过程可表示为：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (2.5)$$

其中， Q 、 K 和 V 分别表示查询矩阵、键矩阵和值矩阵， d_k 表示键向量的维度。通过缩放因子 $\sqrt{d_k}$ ，可以在一定程度上缓解内积结果过大导致梯度不稳定的问题；而 Softmax 函数则用于将相似性分数转换为概率分布形式的权重。

在此基础上，自注意力机制（Self-Attention）进一步将查询、键和值均由同一输入序列映射得到，使模型能够直接建模序列内部不同位置之间的依赖关系。与循环神经网络依赖逐步传递状态不同，自注意力机制能够在一次计算中捕捉任意两个

位置之间的关联，因此在建模长距离依赖关系时具有明显优势。对于具有复杂时空结构的数据，自注意力机制能够有效刻画远距离区域之间以及不同时刻之间的潜在联系，从而提升模型对全局依赖关系的表达能力。

为了从不同表示子空间中学习更加丰富的关联模式，研究者进一步提出了多头注意力机制（**Multi-Head Attention**）。该方法通过设置多个独立的注意力头，对输入特征进行并行映射与注意力计算，使模型能够从多个角度关注输入信息。不同注意力头通常能够捕捉不同层次、不同范围或不同语义的依赖关系，因此多头注意力在提升特征表达能力和增强模型鲁棒性方面具有重要作用。经过多个注意力头并行计算后，其结果会被拼接并映射为最终输出表示，从而实现多视角信息融合。与卷积神经网络相比，注意力机制不依赖固定大小的局部感受野，而是通过数据驱动的方式自适应地分配特征权重，因此更适合建模全局范围内的复杂关联关系。卷积神经网络在提取局部空间模式方面具有优势，但对于跨区域、跨时间的长距离依赖关系刻画能力相对有限；注意力机制则能够弥补这一不足，使模型在保留局部特征的同时，进一步感知全局上下文信息。因此，在实际任务中，卷积操作与注意力机制常被结合使用，以同时兼顾局部建模能力与全局关联建模能力。

在犯罪预测任务中，注意力机制具有较强的适用性。一方面，犯罪行为在时间维度上往往具有明显的周期性、突发性与延续性，不同历史时刻对未来预测结果的重要程度并不相同。例如，近期时间片可能反映犯罪活动的短期变化趋势，而具有相似周期规律的历史时间片则可能为未来风险预测提供补充信息。另一方面，犯罪事件在空间维度上不仅受到邻近区域的影响，还可能与功能相似但地理位置较远的区域存在潜在关联。例如，商业区、交通枢纽或居住区等功能相近区域，即使在地理位置上并不相邻，也可能表现出相似的犯罪分布模式。因此，若仅采用固定权重或局部感受野进行建模，往往难以充分揭示犯罪数据中复杂的跨区域、跨时间依赖关系。通过引入注意力机制，模型能够根据输入数据的变化，自适应地关注对当前预测更为重要的时间片、空间区域及特征维度，从而提升模型对复杂时空模式的表达能力。与传统的特征融合方式相比，注意力机制不再简单地对所有历史信息或区域信息赋予相同权重，而是通过学习不同特征之间的相关性，动态调整各部分信息在预测过程中的贡献程度。这种自适应加权方式能够帮助模型更加有效地捕捉关键时空线索，提高对犯罪风险变化趋势的刻画能力。此外，在犯罪数据通常具有高度稀疏性和分布不均衡性的背景下，注意力机制还能够一定程度上缓解冗余信息和

无效特征对模型学习过程的干扰。由于大部分区域和时间段内犯罪事件较少甚至为零，直接对所有位置进行同等建模容易导致模型受到大量无效信息影响。通过对关键区域与关键时段赋予更高权重，模型可以更有效地聚焦于少量但重要的犯罪模式，从而提升预测的准确性与稳定性。也正因如此，注意力机制已逐渐成为时空预测模型中的重要组成部分，并为后续更加复杂的时空特征融合、全局依赖建模和深层特征交互提供了重要基础。




图 2.5 Transformer 网络结构示意图

Figure 2.5 Schematic diagram of the Transformer network architecture

综上所述，注意力神经网络通过动态权重分配机制增强了模型对关键特征的识别能力，尤其在建模长距离依赖关系、融合多维信息以及突出重要时空模式方面具有明显优势。对于本文所研究的城市犯罪预测任务而言，引入注意力机制不仅有助于弥补传统卷积建模在全局依赖表达上的不足，也为后续构建融合局部与全局信息的时空预测模型提供了重要理论基础。

2.5 本章小结

本章围绕城市犯罪预测任务的理论基础与关键技术进行了系统梳理。从任务背景出发，对犯罪预测的基本概念及其时空特性进行了分析，指出犯罪数据在时空上具有聚集性，周期性与延续性，同时呈现出明显的稀疏性与分布不均衡特征。在此基础上，介绍了常用的评价指标，为后续模型性能评估提供了依据。随后，对犯罪预测问题进行了分类，重点分析了犯罪时空预测、犯罪类型预测以及犯罪嫌疑人预测三类任务。在模型方法方面，本章重点介绍了卷积神经网络与注意力机制。卷积神经网络通过局部连接与权值共享机制，能够有效提取空间局部特征；注意力机制则通过动态分配权重，能够建模长距离依赖关系并突出关键特征。二者在建模能力上的互补性，为复杂时空数据建模提供了重要支持。综上，本章为后续基于卷积与注意力融合的犯罪时空预测模型设计与实现奠定了理论基础。

第三章 基于原型注意力机制的犯罪时空预测模型

3.1 引言

随着犯罪预测方法的不断发展，基于数据驱动的建模策略在刻画犯罪行为的时空演化规律方面取得了一定进展。然而，现有方法在实际应用中仍存在一定局限性。一方面，传统方法及部分深度学习模型主要依赖于局部时空信息进行建模，例如通过卷积操作或邻域结构捕捉相邻区域与相邻时间步之间的依赖关系。这类方法虽然能够有效提取局部特征，但其预测结果在很大程度上仍依赖于局部信息的累积，且难以充分刻画跨区域、跨时间的全局关联性。为弥补这一不足，部分研究尝试在模型中引入全局信息建模机制，例如通过堆叠多层网络结构来扩大感受野或引入复杂的外部数据增强。然而，外部数据的引入往往依赖额外的数据获取与预处理过程，不仅增加了系统实现的复杂度，还可能由于数据来源不一致或质量参差不齐而引入额外噪声，进而影响模型的稳定性与泛化能力。这类方法往往依赖于较深的网络层次或冗余的结构设计，以间接捕捉长距离依赖关系，不仅增加了模型复杂度和计算开销，还可能引入冗余特征，影响模型的表达效率与泛化能力。因此，如何在保证模型表达能力的同时，以更加高效和紧凑的方式建模全局依赖关系，仍然是一个具有挑战性的问题。

此外，犯罪数据普遍存在显著的稀疏性与倾斜性，大量区域在多数时间段内未发生犯罪事件，导致数据分布高度不均衡。这一特性使得模型在训练过程中容易偏向于学习低值或零值模式，从而影响预测结果的准确性与稳定性。因此，如何在建模过程中同时兼顾局部特征提取、全局依赖建模以及稀疏数据处理，成为提升模型性能的关键。针对上述问题，本章提出一种基于全局-局部调制原型注意力机制的犯罪时空预测模型。该模型通过卷积建模历史犯罪数据的时空局部依赖性，全局注意力机制建模时空全局依赖性和周期性，实现对多尺度时空依赖关系的协同建模；同时将注意力嵌入映射到每一个可学习的原型表示以增强全局特征表达能力，并设计两阶段预测机制以缓解数据稀疏带来的影响。通过实验验证，我们提出的方法优于所有的基线表现。

3.2 算法设计

针对城市犯罪数据中局部时空依赖复杂、全局关联难以刻画以及数据稀疏性较强等问题，本章提出一种基于原型注意力机制的犯罪时空预测模型。该模型通过局部依赖建模捕捉细粒度时空变化，通过原型注意力机制建模跨区域、跨时间全局关联，并结合两阶段预测机制缓解稀疏数据带来的预测偏置。下面将从模型总体结构、关键模块设计和预测机制等方面对所提出方法进行详细介绍。

3.2.1 模型总体结构

本章所提出的基于原型注意力机制的犯罪时空预测模型（Global-Local Modulated Prototype Attention Network for Spatio-Temporal Crime Prediction, GL-MoPA）整体结构如图3所示。以多类别犯罪时空序列作为输入，模型旨在同时刻画局部时空模式与全局依赖关系，并通过引入发生感知机制，对数据稀疏性问题进行显式建模。如图 3.1所示，该模型主要由四个核心部分构成：时空嵌入层、局部依赖建模模块、基于原型感知注意力的全局依赖建模模块，以及融合发生概率估计与犯罪强度预测的两阶段预测模块。各模块在结构上以全局与局部协同的方式进行组织，从而在不同的时空尺度上实现特征的互补学习与有效融合。




图 3.1 基于原型注意力机制的犯罪时空预测模型架构图

Figure 3.1 Architecture of the GL-MoPA

模型以多类别犯罪时空序列作为输入，整体流程可以分为特征嵌入、局部依赖建模、全局依赖建模、全局-局部特征融合以及两阶段预测五个部分。首先，原始犯

罪数据由不同犯罪类型在空间区域和时间维度上的历史观测值构成。由于原始犯罪计数通常较为稀疏且表达能力有限，模型首先通过一个可学习的嵌入层将输入数据映射到高维连续特征空间，得到统一的隐层特征表示，为后续的局部建模和全局建模提供基础。在获得嵌入表示后，模型将特征并行送入局部依赖建模模块和全局依赖建模模块。局部依赖建模模块主要用于捕捉邻近区域、相邻时间片以及不同犯罪类型之间的细粒度关联关系。具体而言，该模块利用三维卷积神经网络对输入特征进行局部感受野范围内的联合建模，使模型能够同时感知空间维度、时间维度以及犯罪类型维度上的局部变化模式，从而提取局部时空特征表示。

与局部依赖建模不同，全局依赖建模模块侧重于捕捉跨区域、跨时间的长距离关联关系。该模块首先将嵌入后的时空特征展开为一维序列，并生成查询、键和值等特征表示。随后，通过可学习的卷积聚合操作将细粒度特征映射为一组具有代表性的原型表示，使原型能够概括具有相似时空模式的区域、时间片或犯罪类型特征。在此基础上，模型利用原型感知注意力机制建模输入特征与原型之间的关联关系。在特征融合阶段，模型进一步将局部建模结果与全局建模结果进行协同融合。具体而言，局部特征经过 Sigmoid 函数生成调制权重，用于对全局特征进行自适应加权调整；随后通过哈达玛积和残差连接实现全局信息与局部信息的融合，得到融合后的时空特征表示。该过程使模型既能够保留局部区域中的细粒度变化，又能够利用全局依赖信息增强对复杂犯罪模式的刻画能力。

最后，针对犯罪数据稀疏性较强的问题，模型引入发生概率预测模块，对未来区域内犯罪事件是否发生进行估计，并将其与犯罪强度预测结果相结合。经过发生概率约束后的特征进一步输入预测层，最终输出未来时刻各空间区域及各犯罪类型对应的犯罪强度预测结果。通过上述流程，GL-MoPA 能够在统一框架下同时建模局部时空依赖、全局关联结构以及犯罪发生概率，从而提升模型在稀疏犯罪数据场景下的预测精度与鲁棒性。

3.2.2 嵌入层

由于犯罪计数数据本身具有明显的稀疏性和离散性，若直接对原始犯罪数值进行建模，可能会限制后续特征提取模块的表达能力。为此，本章在模型前端引入一个轻量级嵌入层，将原始犯罪观测值映射到连续的潜在特征空间中，从而为后续的局部依赖建模和全局依赖建模提供更加丰富的特征表示。

具体而言, 给定原始犯罪张量 $X \in \mathbb{R}^{R \times T \times K}$, 其中 R 表示空间区域数量, T 表示总的历史时间步数, K 表示犯罪类型数量。模型首先在通道维度上对原始输入进行扩展, 然后通过一个卷积核大小为 $1 \times 1 \times 1$ 的逐点三维卷积, 将每一个区域、时间和犯罪类型对应的原始观测值投影到 d 维特征空间中。该操作相当于对每个时空犯罪位置进行独立的线性变换, 在提升特征维度的同时, 不改变原始数据的空间结构和时间分辨率。

对于任意一个时空犯罪张量元素 (r, t, k) , 其嵌入过程可表示为:

$$E_{r,t,k} = f_{\text{emb}}(X_{r,t,k}), \quad E_{r,t,k} \in \mathbb{R}^d \quad (3.1)$$

其中, $f_{\text{emb}}(\cdot)$ 表示由 $1 \times 1 \times 1$ 三维卷积实现的可学习嵌入函数, $E_{r,t,k}$ 表示区域 r 在时间步 t 上第 k 类犯罪对应的嵌入向量。经过该嵌入层处理后, 模型得到嵌入后的犯罪特征张量 $E \in \mathbb{R}^{R \times T \times K \times d}$ 。

需要说明的是, 本章所设计的嵌入层并不直接承担具体的空间或时间结构建模任务, 而是作为一种结构无关的特征提升机制, 用于将原始犯罪计数数据转换为更加适合深层网络处理的连续特征表示。通过将特征嵌入阶段与后续的空间依赖建模和时间依赖建模过程相分离, 模型能够在保持输入时空结构不变的基础上, 为后续模块提供更加灵活的特征表示空间。这样一来, 局部依赖建模模块和全局依赖建模模块可以分别从不同尺度出发, 对局部时空模式和长距离依赖关系进行有效刻画, 从而提升整体模型的表达能力。

3.2.3 局部依赖建模

基于 2.1 节的阐述, 犯罪行为在空间和时间维度上均具有明显的局部相关性。从空间角度来看, 相邻区域之间往往存在一定的相互影响关系, 某一区域内犯罪事件的发生可能与周边区域的历史犯罪分布有关; 从时间角度来看, 犯罪行为也常表现出短期连续性, 即当前时刻的犯罪风险通常受到邻近历史时间片的影响。因此, 仅对单一维度进行建模难以充分刻画犯罪数据中的局部时空演化规律。为此, 本章设计局部依赖建模模块, 通过卷积操作对空间邻域、时间邻域以及犯罪类型之间的局部交互关系进行联合建模。

给定嵌入层输出的犯罪特征张量 E , 局部依赖建模模块首先关注空间邻域内的局部相关性。对于每一个时间步, 模型在二维空间网格上对相邻区域进行卷积操作,

从而捕捉不同空间位置之间的局部关联。同时，考虑到不同犯罪类型之间可能存在潜在联系，模型在空间卷积过程中保留犯罪类型维度的信息，使得局部空间特征不仅反映区域邻近关系，也能够体现多类别犯罪之间的交互影响。其空间局部建模过程可表示为：

$$E_{r,t,:}^{(\text{spa})} = \phi \left(E_{r,t,:} + \sum_{i=1}^K W_i^{(\text{spa})} *_{\mathcal{N}(r)} E_{\mathcal{N}(r),t,i} \right) \quad (3.2)$$

其中， $\mathcal{N}(r)$ 表示区域 r 的空间邻域， $W_i^{(\text{spa})}$ 表示第 i 类犯罪对应的空间卷积核， $*_{\mathcal{N}(r)}$ 表示在空间邻域内执行的卷积操作， $\phi(\cdot)$ 表示非线性激活函数。通过该过程，模型能够从局部空间范围内提取相邻区域之间的关联特征。

在获得空间局部表示后，模型进一步沿时间维度建模短期时间依赖关系。空间建模主要刻画“犯罪可能发生在哪里”，而时间建模则进一步关注“犯罪可能在何时发生”。具体而言，模型以当前时间步为中心，在其时间邻域内进行卷积运算，捕捉相邻时间片之间的动态变化趋势。其时间局部建模过程可表示为：

$$E_{r,t,:}^{(\text{tem})} = \phi \left(E_{r,t,:}^{(\text{spa})} + \sum_{i=1}^K W_i^{(\text{tem})} *_{\mathcal{N}(t)} E_{r,\mathcal{N}(t),i}^{(\text{spa})} \right) \quad (3.3)$$

其中， $\mathcal{N}(t)$ 表示当前时间步 t 的时间邻域， $W_i^{(\text{tem})}$ 表示第 i 类犯罪对应的时间卷积核， $*_{\mathcal{N}(t)}$ 表示在时间邻域内执行的卷积操作。该过程能够增强模型对短期时间变化规律的捕捉能力，使其更好地感知犯罪风险在连续时间片中的演化趋势。

进一步地，为了综合不同犯罪类型分支的局部信息，本章采用多分支卷积聚合方式对各类犯罪特征进行融合。空间维度上的多分支聚合可表示为：

$$E_{r,t}^{(\text{spa})} = \phi \left(E_{r,t} + \text{Concat} \left(W_1^{(\text{spa})} * E_{\mathcal{N}(r),t}, \dots, W_K^{(\text{spa})} * E_{\mathcal{N}(r),t} \right) \right) \quad (3.4)$$

时间维度上的多分支聚合可表示为：

$$E_{r,t}^{(\text{tem})} = \phi \left(E_{r,t}^{(\text{spa})} + \text{Concat} \left(W_1^{(\text{tem})} * E_{r,\mathcal{N}(t)}^{(\text{spa})}, \dots, W_K^{(\text{tem})} * E_{r,\mathcal{N}(t)}^{(\text{spa})} \right) \right) \quad (3.5)$$

其中， $\text{Concat}(\cdot)$ 表示特征拼接操作。通过多分支卷积聚合，模型能够分别学习不同犯罪类型在局部空间和局部时间范围内的变化模式，并将其整合为统一的局部时空表示。最后，为了对融合后的局部时空特征进行进一步调整，本章采用可学习的 $1 \times 1 \times 1$ 三维卷积对通道维度进行映射，并结合组归一化操作稳定特征分布，得到

局部依赖建模模块的输出：

$$E_{\text{local}} = \text{GN} \left(W^{(1 \times 1 \times 1)} * E^{(\text{tem})} + b \right) \quad (3.6)$$

其中， $\text{GN}(\cdot)$ 表示组归一化操作， $W^{(1 \times 1 \times 1)}$ 和 b 分别表示可学习的卷积核参数与偏置项。由此得到的局部特征表示 E_{local} 融合了空间连续性、短期时间依赖以及犯罪类型交互信息，能够有效刻画区域级别的细粒度时空模式。

需要指出的是，局部依赖建模模块主要依赖邻近区域和相邻时间片的信息进行特征提取，因而更适合捕捉局部范围内的时空变化。然而，实际城市犯罪模式并不完全由局部邻近关系决定。某些地理位置相距较远但功能属性相似的区域，可能呈现出相近的犯罪分布特征；同时，时间间隔较远但具有相似周期规律的时段，也可能存在潜在关联。此类长距离、非局部依赖关系难以仅通过卷积操作充分建模。因此，本章在局部依赖建模的基础上进一步引入全局依赖建模模块，以增强模型对跨区域、跨时间复杂关联关系的表达能力。

3.2.4 全局依赖建模

在实际场景中，地理位置相距较远但功能属性相似的区域，以及时间间隔较远但活动规律相近的时段，仍可能呈现出相似的犯罪变化模式。因此，仅依赖局部卷积建模难以充分捕捉这类跨区域、跨时间的长距离依赖关系。为增强模型对全局时空结构的表达能力，本章引入基于原型的全局依赖建模方法。与传统自注意力机制直接在细粒度区域或时间点之间计算两两关系不同，该方法将区域、时间和犯罪类型等细粒度特征聚合为一组可学习的原型表示。每个原型可视为对若干具有相似时空模式的区域或时间片的抽象表示，其对应的并不一定是规则网格或连续时间窗口，而是模型根据数据特征自适应学习得到的粗粒度时空单元。为后续原型感知注意力建模提供更加紧凑有效的全局表示。

基于上述思想，本章提出一种原型注意力机制，用于将细粒度的时空特征表示抽象为一组可学习的原型。每个原型对应由多个空间区域和时间步共同组成的不规则大尺度时空单元，使模型能够在原型层面刻画不同区域和时间片之间的交互关系，而不是仅将每个区域或时间点作为孤立单元进行建模。通过这种方式，模型能够突破局部时空点的限制，进一步捕捉地理位置相距较远但功能属性相似的区域之间的潜在关联，以及时间间隔较远但行为模式相近的时间片之间的隐含联系。已有的基

于原型或聚类的表示学习方法通常依赖显式分组策略，例如 k -means 聚类^[38-41]、图划分^[42-44]或基于度量^[45-46]的样本分配等。这类方法往往需要预先计算原型，或在训练过程中通过迭代优化不断更新原型，其效果较大程度上依赖于相似性度量的设计，并且容易受到初始化结果的影响。

本章方法不进行显式聚类，而是通过沿时空犯罪维度的可学习卷积聚合过程隐式学习原型表示。也就是说，模型能够在端到端训练过程中同时学习细粒度区域表示及其到潜在大尺度时空单元的映射关系。该设计避免了固定划分或人工聚类带来的限制，使模型能够更加灵活地从数据中自适应抽象出大尺度犯罪模式。具体而言，设位置编码后的输入特征为 $Z \in \mathbb{R}^{R \times T \times K \times d}$ ，其中 R 表示原型聚合前的空间区域数量， T 表示时间步数， K 表示犯罪类型数量， d 表示特征维度。为了便于后续注意力计算，首先将输入特征展开为一维序列 $Z^b \in \mathbb{R}^{N \times d}$ ，其中 $N = R \times T \times K$ 。随后，分别对 Z^b 进行独立的线性映射，得到查询矩阵、键矩阵和值矩阵。

$$Q = Z^b W_Q, \quad K = Z^b W_K, \quad V = Z^b W_V \quad (3.7)$$

其中， W_Q 、 W_K 和 W_V 分别表示查询、键和值对应的可学习参数矩阵。

需要指出的是，若直接在展开后的细粒度序列上计算自注意力，模型虽然能够获得全局感受野，但也可能弱化大规模城市环境中更高层次的结构规律。为此，本章将细粒度的区域-时间-犯罪类型表示进一步抽象为一组紧凑的潜在原型。每个原型表示由多个空间区域、时间步和不同犯罪类型的犯罪信息共同构成的不规则大尺度时空单元，使模型能够在原型层面建模区域之间和时间片之间的依赖关系，同时保留细粒度区域级表示能力。

具体而言，本章并不直接在 Q 、 K 和 V 之间计算标准自注意力，而是首先通过一个可学习的聚合算子，将键和值表示分别聚合为一组原型表示。得到的原型表示可作为全局注意力计算中的锚点，使每个查询向量能够选择性地关注具有语义代表性的潜在时空区域。原型聚合过程可表示为：

$$\tilde{K} = A_{\text{proto}}(K), \quad \tilde{V} = A_{\text{proto}}(V) \quad (3.8)$$

$$A_{\text{proto}}(\cdot) : \mathbb{R}^{N \times d_h} \rightarrow \mathbb{R}^{P \times d_h}, \quad P \ll N \quad (3.9)$$

其中， $A_{\text{proto}}(\cdot)$ 表示可学习的原型聚合算子， P 表示原型数量，且远小于原始细粒

度序列长度 N ， d_h 表示单个注意力头对应的特征维度。

通过上述方式，每个区域-时间-犯罪类型单元对应的查询向量不再需要关注所有细粒度单元，而是仅需与少量具有代表性的原型进行交互。这样不仅能够降低全局注意力计算的复杂度，也有助于模型从更高层次上捕捉具有相似时空模式的潜在区域结构。随后，查询向量与原型键之间的注意力权重可表示为：

$$A = \text{Softmax} \left(\frac{Q\tilde{K}^\top}{\sqrt{d_h}} \right), \quad A \in \mathbb{R}^{N \times P} \quad (3.10)$$

其中， $A_{i,j}$ 表示第 i 个区域-时间-犯罪类型单元对第 j 个原型的关注程度，反映了细粒度表示与潜在大尺度时空单元之间的关联强度。基于该注意力权重，模型进一步对原型值进行加权聚合，得到全局特征表示：

$$Z_{\text{global}} = A\tilde{V}, \quad Z_{\text{global}} \in \mathbb{R}^{N \times d_h} \quad (3.11)$$

由此得到的 Z_{global} 将原型层面的犯罪模式融入到每个细粒度区域表示中，从而编码全局上下文信息。具体而言，该表示能够同时捕捉远距离区域之间的空间相似性、不同时段之间的周期性变化规律，以及不同犯罪类型之间由原型归纳得到的潜在交互关系。与此同时，由于全局信息最终仍被映射回细粒度区域-时间-犯罪类型单元，模型在获得全局依赖信息的同时，仍能够保持原始的区域级预测分辨率。

3.2.5 全局-局部信息调制

为了将全局依赖表示与局部上下文信息进行有效融合，本章引入一种轻量级调制机制。具体而言，首先利用局部特征生成自适应权重，以反映不同区域级信息在当前预测任务中的相对重要性。随后，使用该权重对全局特征进行调制，并通过残差连接将调制后的全局特征与原始全局表示相结合。该设计使全局依赖信息能够在局部犯罪特征的引导下进行自适应调整，同时保持特征传播过程的稳定性。

局部特征的自适应权重生成过程可表示为：

$$\tilde{E}_{\text{local}} = E_{\text{local}} \odot \sigma(E_{\text{local}}) \quad (3.12)$$

其中， E_{local} 表示局部依赖建模模块输出的局部特征表示， $\sigma(\cdot)$ 表示 Sigmoid 激活函数， $\odot$ 表示哈达玛积，即逐元素乘法。通过该操作，模型能够根据局部特征自身的重要性生成调制权重，从而突出更具判别性的局部信息。

在得到局部调制权重后，本章利用其对全局特征进行自适应调整，并采用残差聚合方式保证全局信息的稳定传递，其计算过程为：

$$\tilde{Z}_{\text{global}} = Z_{\text{global}} + Z_{\text{global}} \odot \tilde{E}_{\text{local}} \quad (3.13)$$

其中， Z_{global} 表示由原型注意力机制得到的全局特征表示， $\tilde{Z}_{\text{global}}$ 表示经过局部信息调制后的全局表示。该过程能够使全局依赖关系根据局部犯罪模式进行动态调整，从而实现全局结构信息与局部细粒度信息之间的互补融合。

最后，为进一步实现通道维度上的特征混合与重标定，本章采用卷积核大小为 $1 \times 1 \times 1$ 的三维卷积对调制后的全局表示进行映射，得到最终融合特征：

$$Z_{\text{fused}} = W^{(1 \times 1 \times 1)} * \tilde{Z}_{\text{global}} + b \quad (3.14)$$

其中， $W^{(1 \times 1 \times 1)}$ 和 b 分别表示可学习的卷积核参数与偏置项， Z_{fused} 表示最终得到的全局-局部融合特征。该融合表示同时包含局部时空变化模式与全局长距离依赖信息，为后续犯罪发生概率预测和犯罪强度预测提供了更加全面的特征基础。

3.2.6 两阶段犯罪预测机制

尽管通过局部依赖建模和全局依赖聚合可以获得较为丰富的时空特征表示，但由于犯罪数据本身具有显著的稀疏性和零值膨胀特征，直接对犯罪数量进行回归预测仍然具有一定困难。在大量区域和时间片中，犯罪事件并不会发生，而少数区域却可能集中出现较多犯罪事件，这种分布不均衡现象容易导致模型在训练过程中偏向于低值预测，从而影响预测结果的准确性与稳定性。

为显式刻画这一特征，本章进一步引入发生感知的两阶段预测机制，将犯罪预测过程划分为犯罪发生概率估计和犯罪强度建模两个部分。具体而言，模型首先基于融合后的时空特征 Z_{fused} 预测不同区域和犯罪类型对应的犯罪发生概率，其计算过程可表示为：

$$P_{\text{occ}} = \sigma(W_{\text{occ}} * Z_{\text{fused}} + b_{\text{occ}}), \quad P_{\text{occ}} \in \mathbb{R}^{R \times K} \quad (3.15)$$

其中， P_{occ} 表示犯罪发生概率矩阵， W_{occ} 和 b_{occ} 分别表示发生概率预测分支中的可学习卷积参数与偏置项， $\sigma(\cdot)$ 表示 Sigmoid 激活函数。

对于每个空间区域 R_i 和犯罪类型 K_i ，模型首先估计对应的犯罪发生概率 $p_{\text{occ},i,k}$ ，用于反映该区域在未来时刻发生第 k 类犯罪事件的可能性。在此基础上，模型进一步预测犯罪发生条件下的潜在犯罪强度 $y_{\text{global},i,k}$ 。最终预测结果由犯罪发生概率与条件犯罪强度共同决定，其计算过程为：

$$\hat{Y} = P_{\text{occ}} \odot Y_{\text{global}}, \quad \hat{Y} \in \mathbb{R}^{R \times K} \quad (3.16)$$

其中， $\hat{Y}$ 表示未来时间步 $T+1$ 的最终犯罪强度预测图， $Y_{\text{global}} \in \mathbb{R}^{R \times K}$ 表示基于融合特征得到的条件犯罪强度预测结果， $\odot$ 表示哈达玛积，即逐元素乘法， R 和 K 分别表示空间区域数量与犯罪类型数量。

通过上述两阶段预测机制，模型能够先判断犯罪事件发生的可能性，再对可能发生的犯罪强度进行估计，从而避免直接回归犯罪数量时受到大量零值样本的过度影响。该机制有助于提升模型对稀疏犯罪数据的适应能力，使预测结果在低犯罪密度区域中更加稳定可靠。

3.3 实验结果与分析

为验证所提出基于原型注意力机制的犯罪时空预测模型模型的有效性，本章在公开犯罪数据集上开展实验分析。首先介绍模型训练过程、实验设置与对比方法，随后从整体预测性能、稀疏区域鲁棒性和关键模块消融等方面对模型进行评估，以全面分析模型在犯罪时空预测任务中的表现。

3.3.1 模型训练与优化

由于犯罪计数数据具有显著的稀疏性和类别不均衡特征，模型在训练过程中容易受到大量零值样本的影响，从而产生预测偏置。为缓解这一问题，本章采用归一化加权均方误差作为回归损失函数，该损失函数对稀少但具有重要意义的非零犯罪事件赋予更高权重。

设 $\hat{Y}_{b,r,k}$ 和 $Y_{b,r,k}$ 分别表示第 b 个批次样本中，区域 r 上第 k 类犯罪的预测强度和真实强度。首先定义二值指示变量：

$$m_{b,r,k} = \mathbb{I}(Y_{b,r,k} > 0) \quad (3.17)$$

其中， $\mathbb{I}(\cdot)$ 表示指示函数。当真实犯罪强度大于 0 时，说明该位置存在犯罪事件，对

应 $m_{b,r,k} = 1$ ；否则 $m_{b,r,k} = 0$ 。基于该指示变量，为每个预测目标分配重新加权系数，使模型更加关注占比更少但有犯罪发生的区域和时间：

$$\omega_{b,r,k} = 1 + (\lambda - 1)m_{b,r,k} \quad (3.18)$$

其中， $\lambda > 1$ 用于控制非零犯罪样本在损失函数中的相对重要程度。由此，稀疏感知的回归损失函数定义为：

$$\mathcal{L}_{\text{reg}} = \frac{\sum_{b,r,k} \omega_{b,r,k} (\hat{Y}_{b,r,k} - Y_{b,r,k})^2}{\sum_{b,r,k} \omega_{b,r,k}} \quad (3.19)$$

该损失函数通过总有效权重对加权误差进行归一化，既能够增强模型对非零犯罪事件的学习能力，又可以避免由于权重放大导致损失值尺度不稳定。

对于犯罪发生概率预测分支，本章根据真实犯罪强度构造二值发生标签：

$$M_{b,r,k} = \mathbb{I}(Y_{b,r,k} > 0) \quad (3.20)$$

其中， $Y_{b,r,k}$ 表示第 b 个样本中区域 r 上第 k 类犯罪的真实计数。具体而言， $M_{b,r,k}$ 的定义如下式所示：

$$M_{b,r,k} = \begin{cases} 1, & Y_{b,r,k} > 0 \\ 0, & Y_{b,r,k} = 0 \end{cases} \quad (3.21)$$

因此， $M_{b,r,k} \in \{0, 1\}$ 用于显式表示对应区域和犯罪类型是否发生犯罪事件，从而使模型能够将犯罪发生建模与犯罪强度回归进行解耦。

进一步地，定义正样本和负样本数量分别为：

$$N^+ = \sum_{b,r,k} M_{b,r,k}, \quad N^- = \sum_{b,r,k} (1 - M_{b,r,k}) \quad (3.22)$$

其中， N^+ 表示发生犯罪事件的样本数量， N^- 表示未发生犯罪事件的样本数量。由于犯罪数据通常较为稀疏，负样本数量往往远大于正样本数量。为缓解这种样本不平衡问题，本章引入动态正样本权重因子 α ：

$$\alpha = \frac{N^-}{N^+ + \epsilon} \quad (3.23)$$

其中， $\epsilon > 0$ 为防止分母为零而引入的极小常数，用于保证数值计算的稳定性。该自

适应权重机制能够提高稀少犯罪发生样本在优化过程中的贡献，避免模型过度偏向于预测所有区域均无犯罪发生。

基于上述权重设置，犯罪发生预测分支采用加权二元交叉熵损失，其定义为：

$$\mathcal{L}_{\text{occ}} = \sum_{b,r,k} [-\alpha M_{b,r,k} \log(P_{b,r,k}^{\text{occ}} + \epsilon) - (1 - M_{b,r,k}) \log(1 - P_{b,r,k}^{\text{occ}} + \epsilon)] \quad (3.24)$$

其中， $P_{b,r,k}^{\text{occ}} \in (0, 1)$ 表示模型预测的犯罪发生概率。该损失函数对正样本项引入权重 α 进行增强，而负样本项保持原有权重。通过这种方式，模型能够更加关注稀少的犯罪发生样本，同时保持对大量零犯罪区域的稳健建模能力。

最终，本章将局部预测分支、全局预测分支以及发生概率预测分支的损失共同作为总体优化目标：

$$\mathcal{L} = \mathcal{L}_{\text{reg}}(Y_{\text{local}}, Y) + \mathcal{L}_{\text{reg}}(Y_{\text{global}}, Y) + \mathcal{L}_{\text{occ}}(P_{\text{occ}}, Y) \quad (3.25)$$

其中， $\mathcal{L}_{\text{reg}}(Y_{\text{local}}, Y)$ 用于约束局部预测分支，使其学习细粒度区域模式； $\mathcal{L}_{\text{reg}}(Y_{\text{global}}, Y)$ 用于约束全局预测分支，使其捕捉长距离依赖关系； $\mathcal{L}_{\text{occ}}(P_{\text{occ}}, Y)$ 则用于指导模型区分犯罪发生与未发生样本。通过端到端联合优化上述目标，模型能够在局部结构、全局上下文以及犯罪发生概率之间实现均衡学习，从而提升犯罪预测的准确性与鲁棒性。

3.3.2 实验设置

本章实验采用公开的纽约市犯罪数据集（NYC-Crimes），该数据集记录了纽约市 2014 年 1 月至 2015 年 12 月期间的犯罪事件，共覆盖 731 天，包含入室盗窃（Burglary）、抢劫（Robbery）、袭击（Assault）和盗窃（Larceny）四类主要犯罪类型。按照时间顺序划分数据集，训练集与测试集比例为 7 : 1，并从训练集中划分一个月数据作为验证集，用于超参数调节和早停策略。在时间维度上，本章以天为单位进行犯罪预测；在空间维度上，将纽约市地理区域划分为分辨率为 $3\text{km} \times 3\text{km}$ 的规则网格，共得到 256 个互不重叠的空间区域。每个网格区域内的犯罪事件被聚合为对应区域的犯罪计数。数据集的具体统计信息如表 3.1 所示。

所有实验均在配备 NVIDIA TITAN RTX GPU（24 GB 显存）和 Intel Xeon Gold 5118 处理器的服务器上完成。为保证实验结果的稳定性与公平性，本章采用网格搜索方法对模型超参数进行调节。其中，网络层数在 $\{1, 3, 5, 7\}$ 中搜索，隐藏特征维

表 3.1 NYC-Crimes 数据集统计信息
Table 3.1 Statistics of the NYC-Crimes dataset

数据集	NYC-Crimes			
时间范围	2014年1月-2015年12月			
犯罪类型	入室盗窃	抢劫	袭击	盗窃
案件数量	31,799	33,453	40,429	85,899

度在 $\{32, 64, 128, 256\}$ 中选择，原型数量在 $\{1024, 2048, 4096\}$ 中确定。根据验证集上的实验表现，卷积核大小固定为 3。受显存限制，批大小设置为 1，并采用梯度累积策略稳定训练过程，累积步数设置为 16。经过多组验证实验，本章最终将网络层数设为 3，隐藏特征维度设为 256，原型数量设为 2048。该组参数能够在训练稳定性与预测性能之间取得较好的平衡，因此作为后续所有实验的默认配置。

为全面验证本章所提出模型的有效性，实验选取多类具有代表性的基线方法进行对比，包括传统统计模型、经典机器学习方法以及近年来广泛应用于时空预测任务的深度学习模型。其中，ARIMA^[47]是一种经典的时间序列统计模型，主要通过自回归、差分和滑动平均等方式刻画历史序列中的线性时间依赖关系，在犯罪预测任务中可作为传统时间建模方法的代表；SVM^[48]是一种经典监督学习方法，能够借助核函数在高维特征空间中构建非线性决策函数，常用于分类和回归任务。对于深度学习时空预测方法，ST-ResNet^[49]通过残差卷积结构分别建模短期邻近性、周期性和长期趋势等时间因素，并利用卷积操作捕捉空间相关性；DeepCrime^[50]是面向犯罪预测任务设计的深度学习模型，在卷积神经网络基础上引入注意力机制，用于突出关键空间区域和重要时间片；STDN^[51]通过动态时间建模和流门控机制融合不同时间上下文，同时利用卷积结构提取空间特征；ST-MetaNet^[52]则引入元学习思想，用于建模不同城市区域之间的异质性，并增强模型在不同空间区域之间的泛化能力。对于图结构时空预测方法，DCRNN^[53]结合扩散卷积和循环神经网络，通过有向图上的随机游走过程建模空间传播关系，并利用编码器-解码器结构刻画时间依赖；STGCN^[54]通过交替堆叠图卷积层和时间卷积层，同时捕捉局部空间依赖与时间动态变化；GWN^[55]进一步引入自适应图学习与扩张时间卷积，能够在不依赖固定图结构的情况下学习潜在空间关系；GMAN^[56]基于多注意力机制构建编码器-解码器结构，用于动态建模图结构数据中的空间交互和时间影响；AGCRN^[57]通过节点自适应图表示学习空间依赖，并结合循环结构建模时间变化；MTGNN^[58]则通过

可学习图结构刻画多变量时间序列之间的潜在依赖关系，并结合图卷积与时间建模模块实现时空预测。除此之外，本章还选取若干与犯罪预测任务更为相关的强基线方法进行比较。STTrans^[59]利用 Transformer 结构中的层次化注意力机制建模长距离时空依赖，能够同时学习全局和局部时空表示；ST-SHN^[60]将空间区域和犯罪类型表示在统一的超图结构中，通过动态超图建模区域之间的高阶空间关系及不同犯罪类型之间的依赖；DMSTGCN^[61]通过动态调整图结构表示，联合刻画多种时间特征和随时间变化的空间依赖关系；ST-HSL^[62]则结合时空超图表示学习和自监督学习目标，在监督信号稀疏的情况下增强区域表示的鲁棒性。参考已有研究设置，本章将 ST-HSL 作为主要的超图类强基线方法，并依据其原始实验配置设置相关超参数，以保证实验比较的公平性。

3.3.3 模型性能分析

如表 3.2 所示，在 NYC-Crimes 数据集上，本章提出的 GL-MoPA 模型在四类犯罪预测任务中均取得了优于超图类基线模型 ST-HSL 的性能表现。具体而言，在入室盗窃（Burglary）预测任务中，GL-MoPA 相比 ST-HSL 分别降低了 1.9% 的 MAE 和 3.8% 的 MAPE；在盗窃（Larceny）预测任务中，MAE 和 MAPE 分别降低了 0.4% 和 1.2%；在抢劫（Robbery）预测任务中，MAE 和 MAPE 分别降低了 4.9% 和 1.7%；在袭击（Assault）预测任务中，MAE 和 MAPE 分别降低了 9.3% 和 9.6%。总体来看，GL-MoPA 相较于 ST-HSL 在 MAE 和 MAPE 上分别取得了平均 4.1% 和 4.6% 的相对性能提升。




图 3.2 不同稀疏程度区域下 GL-MoPA 与 ST-HSL 的性能对比

Figure 3.2 Performance comparison between GL-MoPA and ST-HSL under different sparsity levels

为进一步验证 GL-MoPA 模型在稀疏数据场景下的鲁棒性，本章根据不同区域

表 3.2 模型预测性能对比

Table 3.2 Comparison of model prediction performance

Models	Burglary		Larceny		Robbery		Assault	
	MAE	MAPE	MAE	MAPE	MAE	MAPE	MAE	MAPE
SVM (2011)	1.1604	0.7653	1.4979	0.6417	1.1278	0.6733	1.1928	0.6964
ARIMA (2012)	0.8999	0.6363	1.3015	0.6268	0.9558	0.5969	0.9992	0.6198
ST-ResNet (2017)	0.8680	0.5603	1.1082	0.5478	0.8177	0.5209	0.9645	0.5749
DCRNN (2018)	0.8176	0.5324	1.0732	0.5492	0.9189	0.5532	0.9692	0.5955
STGCN (2018)	0.8366	0.5404	1.0692	0.5295	0.9035	0.5441	0.9375	0.5757
DeepCrime (2018)	0.8227	0.5508	1.0618	0.5351	0.9083	0.5380	0.9222	0.5777
GWN (2019)	0.7993	0.5235	1.0493	0.5405	0.8681	0.5351	0.8866	0.5646
STDN (2019)	0.8831	0.5768	1.1442	0.5889	0.9230	0.5649	0.9498	0.5661
ST-MetaNet (2019)	0.8285	0.5369	1.0697	0.5424	0.9152	0.5766	0.9320	0.5870
STTrans (2020)	0.8167	0.5592	1.0862	0.5473	0.8848	0.5312	0.9139	0.5655
GMAN (2020)	0.8652	0.5633	1.0834	0.5340	0.9234	0.5671	0.9338	0.5803
AGCRN (2020)	0.8260	0.5397	1.0950	0.5404	0.9013	0.5338	0.9063	0.5519
MTGNN (2020)	0.8429	0.5497	1.0375	0.5237	0.9026	0.5363	0.9256	0.5664
ST-SHN (2021)	0.8012	0.5198	1.0431	0.5291	0.8777	0.5362	0.9169	0.5682
DMSTGCN (2021)	0.8376	0.5485	1.0401	0.5464	0.8597	0.5403	0.9306	0.5601
ST-HSL (2022)	0.7329	0.4788	1.0316	0.5040	0.7912	0.4595	0.8484	0.5029
GL-MoPA (Ours)	0.7187	0.4608	1.0272	0.4980	0.7523	0.4518	0.7698	0.4549

的犯罪发生密度对测试区域进行划分。其中，犯罪发生密度定义为区域犯罪时间序列 X_t 中非零记录所占比例。基于该划分标准，本章选取犯罪发生密度不高于 0.5 的低犯罪活跃区域，并进一步将其划分为 $(0, 0.25]$ 和 $(0.25, 0.5]$ ，两个稀疏程度区间。不同稀疏程度区域下的性能对比如图 3.2 所示。在稀疏数据场景下，GL-MoPA 相比 ST-HSL 表现出更明显的鲁棒性优势。在犯罪发生密度为 $(0, 0.25]$ 的高稀疏区域中，GL-MoPA 相比 ST-HSL 分别降低了 10.3% 的 MAE、11.3% 的 MAPE 和 8.7% 的 RMSE。进一步地，在犯罪发生密度为 $(0.25, 0.5]$ 的中等稀疏区域中，GL-MoPA 的性能优势更加明显，其 MAE、MAPE 和 RMSE 分别降低了 17.2%、21.0% 和 10.8%。

上述实验表明 GL-MoPA 不仅在整体预测性能上优于现有强基线模型，而且在

稀疏区域中表现出更加明显的优势。实验结果说明，本章模型能够有效融合局部时空特征与全局依赖信息，并在犯罪事件分布不均衡的情况下保持较稳定的预测能力，从而验证了所提出方法在犯罪时空预测任务中的有效性与鲁棒性。

3.3.4 消融实验分析

为进一步分析 GL-MoPA 模型中各关键模块对预测性能的贡献，本章通过选择性移除模型中的核心组件开展消融实验以验证各模块设计的有效性。通过对完整模型与不同消融变体进行对比，可以更加直观地判断各模块在特征表达、误差降低以及稀疏场景建模中的具体作用。如图 3.3 所示，完整 GL-MoPA 模型在各项整体评价指标上均表现较好。在所有模块中，原型注意力模块对整体误差降低的贡献最为明显。与移除原型注意力模块的模型变体相比，完整模型在 RMSE、MAE 和 MAPE 上分别降低了 23.4%、6.5% 和 6.1%。这一结果表明，原型注意力机制能够有效捕捉全局时空依赖关系，使模型在建模跨区域、时间关联时获得更充分的上下文信息。类似的，与移除局部建模模块的变体相比，完整模型在 RMSE、MAE 和 MAPE 上分别降低了 0.9%、6.9% 和 14.6%。其中，MAPE 指标的下降幅度最为显著，说明局部特征表示对于缓解不同区域之间的相对误差以及刻画细粒度局部变化具有重要作用。这也表明，在犯罪预测任务中，邻近区域、相邻时间片以及不同犯罪类型之间的局部关联仍然是影响预测结果的重要因素，局部依赖建模能够为全局表示提供必要的细节补充。




图 3.3 GL-MoPA 模型在整体评价指标上的消融实验结果

Figure 3.3 Ablation study results of GL-MoPA on overall evaluation metrics

值得注意的是，在整体评价指标上，移除两阶段预测机制的模型变体在 **RMSE**、**MAE** 和 **MAPE** 上表现略优于完整模型。然而，两阶段预测机制的主要目的并非单纯优化整体平均误差，而是针对犯罪数据稀疏性较强的特点，提升模型在低密度区域中的预测稳定性和鲁棒性。如图 3.4 所示，在高稀疏区域 $(0, 0.25]$ 中，**GL-MoPA** 在 **MAPE**、**MAE** 和 **RMSE** 上均取得更低误差；在中等稀疏区域 $(0.25, 0.5]$ 中，完整模型同样保持了略优的预测表现。该结果表明，两阶段预测机制能够在犯罪样本稀少的情況下有效缓解零值样本带来的影响，增强模型对稀疏区域犯罪风险的识别能力，从而验证了该模块设计的必要性。




图 3.4 稀疏区域下两阶段预测机制的消融实验对比

Figure 3.4 Ablation comparison of the two-stage prediction mechanism in sparse regions

此外，本章进一步分析了不同模块在各类犯罪预测任务中的具体作用。如图 3.5 所示，本章分别统计了 **GL-MoPA** 及其不同消融变体在入室盗窃（**Burglary**）、盗窃（**Larceny**）、抢劫（**Robbery**）和袭击（**Assault**）四类犯罪上的 **RMSE**、**MAE** 和 **MAPE** 结果，从而更加细致地评估各模块对不同犯罪类型预测性能的影响。从 **RMSE** 指标来看，移除原型注意力模块后，模型性能下降最为明显，尤其是在盗窃和袭击两类犯罪上误差增幅较大。这说明原型层面的全局交互建模对于稳定预测数值幅度、捕捉跨区域长距离时空依赖关系具有重要作用。相比之下，局部依赖建模更多起到细粒度特征补充的作用，并不是修正整体预测幅度的主要来源。从 **MAE** 指标来看，也可以观察到类似趋势。移除原型注意力模块后，各犯罪类型上的绝对误差普遍上升，进一步说明该模块对整体预测精度具有重要贡献。同时，局部依赖建模模块在降低 **MAE** 方面也发挥了一定作用，尤其是在抢劫和袭击等犯罪类型

中，局部空间线索对预测结果具有较明显影响。相比之下，移除两阶段预测机制后，MAE 变化相对较小，这进一步说明该模块的主要作用并不在于直接优化整体平均误差，而是增强模型在稀疏区域中的预测稳定性。




图 3.5 不同犯罪类型下 GL-MoPA 模型的消融实验结果

Figure 3.5 Ablation study results of GL-MoPA under different crime types

上述消融实验结果表明，GL-MoPA 中各关键模块均具有明确且互补的作用。原型注意力模块主要用于捕捉全局时空依赖关系，对降低整体预测误差和稳定预测幅度具有重要贡献；局部依赖建模模块能够增强模型对细粒度空间变化和局部时空模式的刻画能力，尤其有助于降低相对误差；两阶段预测机制虽然对整体平均指标的提升并不最为显著，但能够有效增强模型在稀疏区域中的预测稳定性。上述结果验证了本章模型结构设计的合理性，也说明各模块共同作用能够提升模型在复杂犯罪时空预测任务中的整体性能与鲁棒性。

3.4 本章小结

本章针对城市犯罪数据中的局部与全局时空依赖建模以及数据稀疏性问题，提出了犯罪时空预测模型 GL-MoPA。该模型首先通过轻量级嵌入层将稀疏离散的犯罪计数映射到连续特征空间；随后结合局部依赖建模模块和原型感知注意力机制，分别捕捉细粒度局部交互关系与跨区域、跨时间全局依赖。在此基础上，模型设计全局-局部信息调制机制，实现局部细节与全局上下文的自适应融合；并通过两阶段犯罪预测机制，将犯罪发生概率估计与犯罪强度预测解耦，以缓解零值样本带来的预测偏置。实验结果表明，GL-MoPA 在 NYC-Crimes 数据集上优于多个基线模型，并在稀疏区域中表现出较强鲁棒性。消融实验进一步验证了各核心模块的有效性，说明本章模型能够较好地适应复杂犯罪时空预测任务。

第四章 基于全局-局部信息增强的犯罪时空预测模型

4.1 引言

第三章针对犯罪数据中局部时空依赖、全局关联关系以及稀疏性问题，构建了基于原型注意力机制的犯罪时空预测模型，并通过原型表示对跨区域、跨时间的长距离依赖关系进行建模。然而，在复杂城市犯罪预测场景中，仅依赖单次全局建模仍可能难以充分挖掘深层时空关联关系。不同空间区域、时间片以及犯罪类型之间往往存在多层次交互关系，模型不仅需要捕捉局部邻域中的细粒度变化，还需要在更大范围内持续整合全局上下文信息。现有部分方法通常通过堆叠卷积层扩大感受野，或借助图结构、循环结构和注意力机制建模时空依赖关系。卷积神经网络在局部特征提取方面具有较强优势，能够有效捕捉邻近区域、相邻时间片以及不同犯罪类型之间的局部变化模式；但其感受野受卷积核大小和网络层数限制，对跨区域、跨时间的长距离依赖关系刻画能力相对不足。相比之下，自注意力机制能够直接计算不同输入单元之间的相关性，适合建模全局上下文信息。然而，标准自注意力在长时空序列上通常具有较高计算复杂度，当输入同时包含空间区域、时间步和犯罪类型信息时，直接计算完整注意力矩阵会带来较大的计算开销。

为进一步提升模型对复杂时空依赖关系的表达能力，并兼顾全局建模效率，本章提出一种基于全局-局部信息增强的犯罪时空预测模型。该模型首先通过提取犯罪数据中的局部时空特征，包括空间-类型相关性和时间-类型相关性；随后引入时空位置编码模块，将显式位置信息融入局部特征表示；在此基础上，设计高效全局自注意力模块，通过低秩投影方式降低注意力计算复杂度，同时保留对全局犯罪模式的建模能力。进一步地，本章将全局注意力、局部调制和卷积前馈网络封装为可堆叠的全局信息增强模块，使模型能够逐层整合全局上下文与局部细节信息，从而增强对复杂犯罪时空模式的刻画能力。与第三章方法相比，本章模型不再侧重于通过原型表示抽象不规则大尺度区域，而是重点研究如何通过高效注意力和模块化堆叠机制实现深层全局-局部信息交互。通过这种设计，模型能够在保持局部细粒度感知能力的同时，更高效地捕捉远距离区域和长时间跨度之间的潜在依赖关系。

4.2 算法设计

本章针对犯罪时空预测中局部变化模式复杂、全局长距离依赖难以充分刻画以及多维特征融合不足等问题，提出一种基于全局-局部信息增强的犯罪时空预测模型 GLA-STN。该模型以多类别犯罪时空序列为输入，首先通过局部特征提取模块捕捉空间区域、时间片和犯罪类型之间的细粒度关联；随后利用全局信息增强模块建模跨区域、跨时间以及跨犯罪类型的深层依赖关系，并设计上下文信息融合模块进一步增强局部特征与全局表示之间的交互。整体结构采用模块化设计，能够通过堆叠全局增强模块逐层整合更丰富的时空上下文信息。下面将从模型总体架构、局部特征提取、全局信息增强、上下文信息融合以及模块堆叠结构等方面对本章所提出的方法进行详细说明。

4.2.1 模型总体架构

为同时刻画犯罪数据中的局部时空变化模式与全局长距离依赖关系，本章提出基于全局-局部信息增强的犯罪时空预测模型（Global-Local Attention Enhanced Spatial-Temporal Network for Crime Forecasting, GLA-STN）。该模型整体上采用“局部特征提取—全局信息增强—预测输出”的结构设计。首先，利用局部建模模块对原始多类别犯罪时空序列进行局部建模，提取空间邻域、时间邻域以及犯罪类型之间的细粒度关联特征；随后，通过可堆叠的全局信息增强模块进一步建模跨区域、跨时间的全局依赖关系，并将全局上下文信息与局部特征进行交互融合；最后，将融合后的特征输入预测层，输出未来时刻各区域、各犯罪类型的犯罪强度预测结果。GLA-STN 模型的总体结构如图 4.1 所示。图中虚线框分别展示了局部建模模块、卷积前馈网络以及全局信息增强模块的内部结构。其中，圆圈中的符号 $\odot$ 表示哈达玛积操作，用于实现特征之间的逐元素调制；符号 $\oplus$ 表示残差连接或特征相加操作，用于保持特征传播的稳定性。与仅依赖单一卷积或单一注意力结构的方法不同，本章模型通过将局部卷积建模与高效全局自注意力机制相结合，使模型既能够捕捉局部区域中的细粒度变化，又能够感知更大范围内的全局犯罪模式。

从模型流程来看，输入的多类别犯罪张量首先进入局部建模模块。该模块由犯罪特征嵌入层、空间-类型卷积、时间-类型卷积以及组归一化层组成。其中，嵌入层用于将原始犯罪计数映射到高维连续特征空间；空间-类型卷积用于捕捉不同空间区域与犯罪类型之间的局部关联；时间-类型卷积则进一步建模相邻时间片与犯罪类型

之间的短期依赖关系。经过处理后，模型得到包含局部时空信息的特征表示 Z_{stem} 。随后，局部特征被送入多个串联的全局信息增强模块。每个全局信息增强模块主要包括位置编码层、高效全局自注意力层、组归一化层以及卷积前馈网络。其中，位置编码层用于向局部特征中注入显式的时空位置信息；高效全局自注意力层通过低维投影方式降低注意力计算复杂度，并在统一序列中建模空间区域、时间步和犯罪类型之间的长距离依赖关系；卷积前馈网络则在通道映射的同时进一步融合局部上下文信息。通过多个全局信息增强模块的堆叠，模型能够逐层整合全局上下文与局部细节特征，从而增强对复杂犯罪时空模式的表达能力。




图 4.1 全局-局部信息增强的犯罪时空预测模型架构图

Figure 4.1 Architecture of the GLA-STN model

最后，模型将全局增强后的特征与前端局部建模模块提取的局部特征进行融合，并输入预测层得到最终输出。该结构一方面保留了卷积神经网络对局部时空模式的敏感性，另一方面利用高效自注意力机制增强了模型对长距离依赖关系的建模能力。由于全局信息增强采用模块化设计，其堆叠层数可以根据不同任务和数据规模灵活调整，从而提高模型的适应性与扩展性。

4.2.2 局部特征提取

在所提出的 GLA-STN 模型中，局部特征提取模块位于模型前端，主要用于将原始犯罪张量转换为包含局部时空结构信息的特征表示。与直接将原始犯罪序列输入注意力模块不同，该模块能够在模型前端引入卷积神经网络的局部归纳偏置，使模型优先感知邻近空间区域、短期时间片以及犯罪类型之间的局部交互关系。具体而言，给定输入犯罪张量，模型首先通过特征嵌入层将原始犯罪计数映射到高维连续空间。随后，局部特征提取模块依次采用犯罪类型卷积和时间卷积进行局部特征提取。其中，犯罪类型卷积用于建模空间区域与不同犯罪类型之间的局部关联，时间卷积则进一步沿时间维度刻画短期连续变化及犯罪类型之间的交互模式。经过上述处理后，模型得到局部特征表示 $Z_{\text{stem.cnn}}$ ，并通过组归一化操作稳定特征分布。

给定原始犯罪张量 $X \in \mathbb{R}^{R \times T \times C}$ ，其中 R 、 T 和 C 分别表示空间区域数量、时间步数和犯罪类型数量。对于任意一个区域-时间-犯罪类型位置 (r, t, c) ，模型通过三维卷积嵌入函数 $f_{\text{emb}}(\cdot)$ 将标量犯罪计数 $X_{r,t,c}$ 映射为 d 维嵌入向量，其计算过程如下式所定义：

$$E_{r,t,c} = f_{\text{emb}}(X_{r,t,c}), \quad E_{r,t,c} \in \mathbb{R}^d \quad (4.1)$$

经过特征嵌入层后，原始犯罪张量被转换为高维嵌入表示 $E \in \mathbb{R}^{R \times T \times C \times d}$ 。该表示在保留区域、时间和犯罪类型索引结构的同时，增强了原始离散犯罪计数的特征表达能力，为后续局部特征提取模块提供输入。

犯罪行为在真实城市环境中通常并非随机分布，而是与地理空间结构密切相关。不同类型犯罪在空间上往往呈现出明显的聚集性，即某些犯罪类型更容易在特定区域内高频发生。当某一区域逐渐形成犯罪热点时，其周边区域的犯罪风险也可能随之升高，这种现象通常与犯罪活动的空间溢出效应有关。同时，城市不同区域之间的犯罪发生频率存在显著差异，体现出犯罪空间分布的异质性和复杂空间依赖关系。为刻画上述空间关联特征，本章在局部特征提取模块中设计空间-类型卷积结构，用于联合建模空间区域与犯罪类型之间的局部依赖关系。具体而言，在每一个时间步 t ，模型针对不同犯罪类型分别进行空间卷积操作，并将各犯罪类型对应的空间特征进行拼接融合，从而得到该时间步下的空间-类型联合表示。计算过程为：

$$Z_t^{(R)} = \sigma \left[\delta \left(\text{Concat}_{c=1}^C \{ W_c^{(R)} * E_{t,c} + b_c^{(R)} \} \right) + E_t \right] \quad (4.2)$$

其中, $E_t \in \mathbb{R}^{M \times N \times C \times d}$ 表示在时间步 t 上的嵌入特征张量, 由完整嵌入张量沿时间维度切片得到, d 表示特征嵌入维度。由于城市区域被划分为规则网格, 每个空间区域 $r \in \mathcal{R}$ 对应一个网格单元, 因此空间区域总数满足 $R = M \times N$, 其中 M 和 N 分别表示网格的行数和列数, C 表示犯罪类型数量。 $E_{t,c} \in \mathbb{R}^{M \times N \times d}$ 表示时间步 t 上第 c 类犯罪对应的嵌入特征切片。

在上述公式中, $W_c^{(R)} \in \mathbb{R}^{m \times n}$ 表示与第 c 类犯罪对应的空间卷积核, m 和 n 分别表示卷积窗口在行方向和列方向上的大小, $b_c^{(R)}$ 表示对应的偏置项。符号 $*$ 表示空间卷积操作, $\delta(\cdot)$ 表示卷积后的 Dropout 操作, $\sigma(\cdot)$ 表示 LeakyReLU 激活函数。该卷积操作在不同犯罪类型上分别执行, 同时保持时间维度不变, 从而使模型能够在每个时间步内捕捉空间区域与犯罪类型之间的局部交互关系。最终得到的 $Z_t^{(R)} \in \mathbb{R}^{M \times N \times C \times d}$ 表示时间步 t 下的空间-类型联合特征表示。该表示不仅包含不同空间区域之间的局部相关性, 也保留了不同犯罪类型在空间分布上的差异特征, 为后续时间-类型卷积和全局信息增强模块提供局部结构化输入。

考虑到犯罪行为同时也具有明显的时间连续性和周期性。在相邻时间段内, 由于城市环境状态、社会活动节奏、人口流动规律以及居民日常行为模式具有一定延续性, 犯罪事件的发生模式往往也表现出相对一致的变化趋势。因此, 在完成空间-类型卷积之后, 本章进一步设计时间-类型卷积结构, 用于刻画相邻时间片之间的短期依赖关系以及不同犯罪类型在时间维度上的交互特征。具体而言, 时间-类型卷积以空间-类型卷积模块的输出作为输入, 并沿时间维度对不同犯罪类型分别进行卷积操作。其计算过程可表示为:

$$Z_r^{(T)} = \sigma \left[\delta \left(\text{Concat}_{c=1}^C \left\{ W_c^{(T)} * Z_{t,c}^{(R)} + b_c^{(T)} \right\} \right) + Z_t^{(R)} \right] \quad (4.3)$$

其中, $Z_t^{(R)} \in \mathbb{R}^{M \times N \times C \times d}$ 表示空间-类型卷积模块的输出, $Z_{t,c}^{(R)}$ 表示在固定空间位置下第 c 类犯罪对应的时间序列特征。 $W_c^{(T)}$ 表示第 c 类犯罪对应的时间卷积核, 其卷积窗口大小为 l , 用于捕捉相邻时间片之间的局部动态变化; $b_c^{(T)}$ 表示对应的偏置项。符号 $*$ 表示时间维度上的卷积操作, $\delta(\cdot)$ 表示 Dropout 操作, $\sigma(\cdot)$ 表示 LeakyReLU 激活函数。

经过空间-类型卷积和时间-类型卷积的联合建模后, 模型得到包含局部犯罪依赖关系的特征张量 $Z^{(T)} \in \mathbb{R}^{R \times T \times C \times d}$ 。为进一步稳定特征分布, 并提升后续全局信息增强模块的训练稳定性, 本章对该局部特征表示进行组归一化处理, 使其分布保

持在相对稳定的范围内，从而缓解深层网络训练过程中可能出现的特征分布偏移问题。经过该处理后，得到的 $Z_{\text{stem_cnn}}$ 可作为局部特征提取模块的输出，既包含空间邻域、时间邻域和犯罪类型之间的局部交互信息，也为后续位置编码层和全局信息增强模块提供稳定的输入表示。

$$Z_{\text{stem_cnn}} = \text{GroupNorm}(Z^{(T)}) \quad (4.4)$$

需要说明的是，本节中的局部特征提取模块与第三章中的局部依赖建模模块在基本思想上具有一定联系，二者均利用卷积操作捕捉邻近区域、相邻时间片以及不同犯罪类型之间的局部关联关系。不同之处在于，第三章将局部依赖建模作为全局-局部原型注意力框架中的一个独立分支，并通过局部特征对原型全局表示进行调制；而本章中的局部特征提取模块主要作为 GLA-STN 模型的前端特征提取结构，用于为后续全局信息增强模块提供具有局部时空先验的基础表示。因此，本节不再重复展开局部卷积建模的基本动机，而重点说明其在本章模型中的功能定位及其与后续全局信息增强模块之间的衔接关系。

4.2.3 全局信息增强

在全局自注意力计算中，若直接将局部特征展开为一维序列，模型虽然能够计算不同位置之间的相关性，但可能弱化原始犯罪数据中的空间位置和时间顺序信息。传统 Transformer 通常采用固定的正弦或余弦位置编码来表示序列位置信息，但该方式主要面向一般序列建模任务，难以充分适应犯罪数据中空间分布不均匀、时间变化具有局部连续性的特点。为此，本章在全局信息增强模块中引入基于卷积的位置编码层，使模型能够从局部特征中自适应学习空间与时间位置信息。

具体而言，位置编码层以局部特征提取模块输出的 $Z_{\text{stem_cnn}}$ 作为输入，先利用深度可分离三维卷积对空间维度进行位置编码，再沿时间维度进一步融合邻近时间片信息。对于第 i 个通道，空间位置编码过程可表示为：

$$\text{SpaPos}(Z)_{i,t,m,n} = \sum_{k_1} \sum_{k_2} W_{i,k_1,k_2} \cdot Z_{i,t,m+k_1,n+k_2} + b_i \quad (4.5)$$

其中， W_{i,k_1,k_2} 表示第 i 个通道对应的空间卷积核参数， k_1 和 k_2 分别表示卷积核在空间行方向和列方向上的偏移， m 和 n 表示当前空间网格位置， b_i 为偏置项。 $\text{SpaPos}(Z)_{i,t,m,n}$ 表示在时间步 t 下，空间位置 (m,n) 经过空间卷积编码后得到的位

置感知特征。在获得空间位置编码后，模型进一步沿时间维度进行时间位置编码，用于捕捉邻近时间片之间的局部时序关系，其计算过程为：

$$\text{TimPos}(Z)_{i,t,m,n} = \sum_{k_3} W'_{i,k_3} \cdot \text{SpaPos}(Z)_{i,t+k_3,m,n} + b_i \quad (4.6)$$

其中， W'_{i,k_3} 表示第 i 个通道对应的时间卷积核参数， k_3 表示时间维度上的卷积偏移。该过程能够在保持空间位置结构的同时，将当前时间步附近的时间上下文信息融入特征表示中。

最后，本章将卷积式位置编码结果与原始局部特征进行残差连接，得到具有时空位置感知能力的特征表示：

$$Z_{\text{pos}} = Z_{\text{stem_cnn}} + \text{TimPos}(\text{SpaPos}(Z_{\text{stem_cnn}})) \quad (4.7)$$

通过上述设计，位置编码层能够以数据驱动方式学习犯罪数据中的空间邻近关系和时间局部连续性，而不依赖固定形式的位置编码。得到的 Z_{pos} 不仅保留了局部特征提取模块中的空间-时间-类型交互信息，还进一步显式融入了位置感知信息，为后续高效全局自注意力层建模长距离依赖关系提供更加稳定和充分的输入表示。

在获得位置感知特征 Z_{pos} 后，模型需要进一步建模跨区域、跨时间以及跨犯罪类型的长距离依赖关系。传统自注意力机制能够通过计算序列中任意两个元素之间的相关性来捕捉全局信息，但其计算复杂度随序列长度 n 呈二次增长，即为 $O(n^2)$ 。在犯罪预测任务中，输入序列同时包含空间区域、时间步以及犯罪类型信息，展开后的序列长度通常较长，若直接计算完整注意力矩阵，将带来较大的计算开销和显存消耗。为提高全局依赖建模效率，本章引入一种基于低秩投影思想的高效全局自注意力层。该方法借鉴 **Linformer** 机制^[63]，通过对键矩阵和值矩阵沿序列维度进行可学习压缩，将标准自注意力的计算复杂度由 $O(n^2)$ 降低为 $O(nk)$ ，其中 $k \ll n$ 。与直接构造完整注意力矩阵不同，该方法利用低维键值表示近似原始长序列中的主要相关结构，从而在降低计算开销的同时保留主要全局依赖信息。对于犯罪预测任务而言，输入序列同时包含空间区域、时间步和犯罪类型信息，展开后的序列长度较长。与此同时，犯罪数据通常具有空间聚集性、时间周期性以及犯罪类型之间的共现关系，许多空间-时间-犯罪类型单元之间存在一定相关性。因此，模型并不一定需要对所有细粒度单元进行完全独立的两两交互，而可以通过低秩投影保留主要全局相关模式，从而提升全局注意力建模的效率。

具体而言，首先将位置感知特征 Z_{pos} 展开为一维序列，并通过线性映射得到查询矩阵 Q 、键矩阵 K 和值矩阵 V 。不同于标准自注意力直接基于完整的 K 和 V 进行计算，本章采用一维卷积沿序列维度对 K 和 V 进行可学习降维，得到压缩后的键矩阵和值矩阵：

$$\tilde{K} = \text{Conv1D}(K), \quad \tilde{V} = \text{Conv1D}(V) \quad (4.8)$$

其中， $\text{Conv1D}(\cdot)$ 表示沿序列维度执行的一维卷积操作，其卷积核大小和步长用于将序列长度由 n 降低至 k 。基于降维后的 $\tilde{K}$ 和 $\tilde{V}$ ，高效全局注意力计算过程可表示为：

$$\text{Attention}(Q, \tilde{K}, \tilde{V}) = \text{Softmax} \left(\frac{Q\tilde{K}^T}{\sqrt{d}} \right) \tilde{V} \quad (4.9)$$

其中， d 表示特征维度。经过降维处理后，注意力矩阵的规模由原始的 $\mathbb{R}^{n \times n}$ 降低为 $\mathbb{R}^{n \times k}$ ，从而显著减少全局注意力计算的复杂度。

为了更清晰地描述注意力权重在犯罪预测任务中的含义，可将展开后的一维索引还原为空间-时间-犯罪类型索引。对于任意一个空间区域 r 、时间步 t 和犯罪类型 c ，其对降维后位置 (r', t', c') 的全局注意力权重可表示为：

$$a_{(r,t,c),(r',t',c')} = \frac{\exp \left(Q_{r,t,c} \tilde{K}_{r',t',c'}^T \right)}{\sum_{r'',t'',c''} \exp \left(Q_{r,t,c} \tilde{K}_{r'',t'',c''}^T \right)} \quad (4.10)$$

该权重反映了当前空间-时间-犯罪类型单元与其他潜在相关单元之间的全局关联强度。通过上述注意力计算，模型得到全局特征表示：

$$H_{\text{global}} \in \mathbb{R}^{R \times T \times C \times d} \quad (4.11)$$

在获得全局特征后，本章进一步利用局部位置感知特征对全局表示进行调制，使全局依赖信息能够根据局部犯罪模式进行自适应调整。首先，局部特征通过 Sigmoid 激活函数生成自适应权重：

$$\tilde{Z}_{\text{pos}} = Z_{\text{pos}} \odot \sigma(Z_{\text{pos}}) \quad (4.12)$$

其中， $\odot$ 表示哈达玛积， $\sigma(\cdot)$ 表示 Sigmoid 激活函数。随后，利用局部调制权重与

全局特征进行逐元素交互，得到融合后的局部-全局特征表示：

$$\tilde{H}_{\text{global}} = \left(\tilde{Z}_{\text{pos}} \odot \sigma(H_{\text{global}}) \right) \odot H_{\text{global}} \quad (4.13)$$

通过上述过程，高效全局自注意力层能够在较低计算开销下捕捉长距离时空依赖关系，同时借助局部特征调制机制保留细粒度时空信息。该设计使模型既能够感知远距离区域和长时间跨度之间的潜在关联，又能够根据局部犯罪模式动态调整全局信息的表达，为后续卷积前馈网络和全局信息增强模块的堆叠提供基础。

4.2.4 上下文信息融合

在传统 Transformer 结构中，前馈网络通常由逐位置的多层感知机（Multi-Layer Perceptron, MLP）构成，其主要作用是在注意力层之后对每个位置的特征进行非线性映射和通道变换。然而，传统 MLP 通常针对各位置独立进行特征变换，难以进一步利用犯罪数据中存在的局部空间和时间上下文信息。对于犯罪预测任务而言，全局自注意力层虽然能够捕捉长距离依赖关系，但在特征更新过程中仍有必要保留邻近区域和相邻时间片中的细粒度局部模式。为此，本章通过设计卷积前馈增强模块，用卷积结构替代传统前馈网络中的全连接映射，从而在完成通道变换的同时进一步融合局部时空上下文信息。具体而言，该模块首先采用 $1 \times 1 \times 1$ 逐点卷积对输入全局特征进行通道映射，将特征投影到更高维空间，以增强模型的非线性表达能力；随后，引入深度可分离三维卷积对扩展后的高维特征进行局部空间和时间过滤，使模型能够在前馈变换过程中继续感知邻域范围内的细粒度时空变化；最后，再通过一个 $1 \times 1 \times 1$ 逐点卷积将特征映射回原始维度，得到更新后的特征表示。这一过程可以被表示为：

$$H_{\text{global}}^{(1)} = W_{\text{pw1}} * H_{\text{global}} + b_{\text{pw1}} \quad (4.14)$$

$$H_{\text{global}}^{(2)} = W_{\text{dw}} * H_{\text{global}}^{(1)} \quad (4.15)$$

$$H_{\text{global}}^{(3)} = W_{\text{pw2}} * H_{\text{global}}^{(2)} + b_{\text{pw2}} \quad (4.16)$$

其中， W_{pw1} 和 W_{pw2} 分别表示两个 $1 \times 1 \times 1$ 逐点卷积的卷积核参数， b_{pw1} 和 b_{pw2} 表示对应的偏置项。 W_{dw} 表示深度可分离三维卷积核， $*$ 表示三维卷积操作。第一

个逐点卷积主要用于扩展通道维度，增强特征表达能力；深度可分离三维卷积用于在空间和时间维度上聚合邻域上下文；第二个逐点卷积则用于将特征压缩回目标维度，实现通道重标定。通过上述设计，卷积前馈增强模块不仅保留了传统前馈网络的通道映射能力，还进一步引入了卷积操作的局部建模优势。与直接采用全连接层相比，该模块能够在较低参数量和较小显存开销下完成特征变换，同时增强模型对局部时空细节的感知能力。由此，全局自注意力层捕捉到的长距离依赖关系可以在卷积前馈增强模块中进一步细化，从而提升模型对复杂犯罪时空模式的表达能力。

4.2.5 全局增强模块的堆叠结构

在完成位置编码、高效全局自注意力计算以及上下文信息融合后，本章进一步将上述结构封装为一个完整的全局增强单元。该单元由位置编码层、高效全局自注意力层、上下文信息融合模块以及卷积前馈增强模块组成，并通过残差连接和归一化操作保证深层网络训练过程的稳定性。通过这种模块化设计，模型可以根据任务复杂度和数据规模灵活调整全局增强单元的堆叠层数，从而逐步增强对全局上下文信息的建模能力。

具体而言，设第 l 个全局增强单元的输入特征为 $F^{(l)}$ 。对于第一个全局增强单元，其输入初始化为位置感知局部特征 Z_{pos} ；对于后续单元，其输入则为前一层全局增强单元的输出。该过程可表示为：

$$F^{(l)} = F^{(l)} + \text{CPE}(F^{(l)}) \quad (4.17)$$

其中， $\text{CPE}(\cdot)$ 表示卷积式位置编码操作，用于进一步补充特征中的空间与时间位置信息。随后，模型对位置增强后的特征进行归一化，并输入高效全局自注意力层以捕捉长距离依赖关系。该过程采用残差连接进行特征更新：

$$F^{(l)} = F^{(l)} + \text{Drop}[\text{AttentionLayer}(\text{GN}_1\{F^{(l)}\})] \quad (4.18)$$

其中， $\text{GN}_1(\cdot)$ 表示组归一化操作， $\text{AttentionLayer}(\cdot)$ 表示高效全局自注意力层， $\text{Drop}(\cdot)$ 表示 Dropout 操作。该步骤能够在保持原始特征信息的同时，将全局依赖关系注入当前特征表示中。最后，经过注意力更新后的特征进一步输入卷积前馈增

强模块，以实现通道映射和局部上下文补充，其计算过程为：

$$F^{(l+1)} = F^{(l)} + \text{Drop} [\text{ConvFFN} \{ \text{GN}_2 (F^{(l)}) \}] \quad (4.19)$$

其中， $\text{GN}_2(\cdot)$ 表示第二个组归一化操作， $\text{ConvFFN}(\cdot)$ 表示卷积前馈增强模块。该步骤能够在全局注意力建模的基础上进一步融合局部时空上下文信息，并得到下一层全局增强单元的输入 $F^{(l+1)}$ 。通过串联堆叠多个全局增强单元，模型可以逐层聚合更深层次的全局上下文信息。较浅层模块主要关注局部特征与初步全局依赖之间的交互，而随着层数加深，模型能够进一步整合跨区域、跨时间以及跨犯罪类型的复杂关联关系。残差连接的引入有助于缓解深层堆叠过程中的梯度传播问题，同时保留前层特征中的有效信息，从而提升模型训练的稳定性和整体表达能力。

4.3 实验结果与分析

为验证所提出 GLA-STN 模型在犯罪时空预测任务中的有效性，本章在 NYC-Crimes 和 Chicago-Crimes 两个真实犯罪数据集上开展实验分析。首先介绍模型训练过程、损失函数设计和实验参数设置；随后将所提出模型与多种基线方法进行对比，分析其在不同城市数据集和不同犯罪类型上的预测性能；最后通过稀疏区域鲁棒性实验和消融实验，进一步验证模型在稀疏数据场景下的稳定性以及各关键模块的有效性。章节引言通常需要交代研究目的、背景和后文结构，以帮助读者理解后续内容的组织逻辑。

4.3.1 模型训练与优化

由于犯罪预测数据中存在大量零值样本，模型在训练过程中容易受到零值区域的主导影响，从而倾向于预测较低的犯罪强度。为缓解犯罪数据稀疏性和分布不均衡带来的影响，本章在模型训练过程中采用稀疏加权均方误差损失函数，对真实发生犯罪的非零区域赋予更高权重，使模型在保持对零值区域建模能力的同时，更加关注少量但具有重要意义的犯罪发生样本。具体而言，设 $p_{b,r,c}$ 和 $y_{b,r,c}$ 分别表示第 b 个批次样本中，区域 r 上第 c 类犯罪的预测值和真实值。首先，根据真实犯罪计数

构造二值掩码变量：

$$m_{b,r,c} = \begin{cases} 1, & y_{b,r,c} > 0, \\ 0, & y_{b,r,c} = 0. \end{cases} \quad (4.20)$$

其中， $m_{b,r,c} = 1$ 表示该区域对应犯罪类型在预测目标中存在犯罪事件， $m_{b,r,c} = 0$ 表示该位置未发生犯罪事件。基于该掩码变量，为每一个预测目标分配加权系数：

$$w_{b,r,c} = 1 + (\alpha - 1)m_{b,r,c}, \quad (4.21)$$

其中， α 为权重超参数，用于控制非零犯罪样本在损失函数中的相对重要程度。当 $y_{b,r,c} = 0$ 时，权重保持为 1；当 $y_{b,r,c} > 0$ 时，权重提升为 α ，从而增强模型对犯罪发生区域的学习强度。最终，稀疏加权均方误差损失函数定义为：

$$\mathcal{L} = \frac{\sum_{b,r,c} w_{b,r,c} (p_{b,r,c} - y_{b,r,c})^2}{\sum_{b,r,c} w_{b,r,c}}. \quad (4.22)$$

该损失函数通过总权重对加权误差进行归一化，避免由于权重放大导致损失尺度不稳定的问题。与普通均方误差相比，稀疏加权损失能够提高非零犯罪样本对模型优化过程的贡献，使模型更加关注实际发生犯罪的区域和类型。在具体训练过程中，超参数 α 从预设候选集合中选取，并根据验证集表现确定最终取值。较大的 α 能够进一步提高模型对稀疏犯罪事件的关注程度，但若取值过大，可能使模型过度拟合少量非零样本；较小的 α 则会削弱加权机制对稀疏样本的补偿作用。实验中，通过验证集调节 α ，使模型在关注非零犯罪区域和保持整体预测稳定性之间取得平衡。

4.3.2 实验设置

为验证本章所提出 GLA-STN 模型的有效性，本章在两个公开真实犯罪数据集上开展实验，分别为纽约市犯罪数据集（NYC-Crimes）和芝加哥犯罪数据集（Chicago-Crimes）。实验内容包括模型性能对比、稀疏区域鲁棒性分析以及消融实验分析。通过与多类基线模型进行比较，可以全面评估本章模型在不同城市环境、不同犯罪类型以及不同稀疏程度场景下的预测能力。NYC-Crimes 数据集记录了纽约市 2014 年 1 月至 2015 年 12 月期间的犯罪事件，共覆盖 731 天，包含入室盗窃（Burglary）、盗窃（Larceny）、抢劫（Robbery）和袭击（Assault）四类犯罪类型。Chicago-Crimes 数据集记录了芝加哥市 2016 年 1 月至 2017 年 12 月期间的犯罪事

件，包含盗窃（Theft）、殴打（Battery）、袭击（Assault）和刑事损害（Damage）四类犯罪类型。两个数据集均以天为时间分辨率进行预测，并按照时间顺序划分训练集、验证集和测试集。其中，训练集与测试集按照 7 : 1 的比例划分，并从训练阶段中选取最后 30 天作为验证集。

在空间维度上，本章采用规则网格划分方式对城市区域进行离散化。对于 NYC-Crimes 数据集，将纽约市划分为分辨率为 $3\text{km} \times 3\text{km}$ 的空间网格，共得到 256 个互不重叠的区域；对于 Chicago-Crimes 数据集，采用相同的空间划分策略，共得到 168 个空间区域。每个区域内的犯罪事件按照时间步和犯罪类型进行聚合，形成模型输入所需的多类别犯罪时空张量。两个数据集的具体统计信息如表 4.1 所示。

表 4.1 实验数据集统计信息
Table 4.1 Statistics of the experimental datasets

数据集	NYC-Crimes				Chicago-Crimes			
时间范围	2014年1月–2015年12月				2016年1月–2017年12月			
犯罪类型	入室盗窃	抢劫	袭击	盗窃	盗窃	殴打	袭击	刑事损害
案件数量	31,799	33,453	40,429	85,899	124,630	99,389	37,972	59,886

此外，为分析模型在稀疏犯罪数据场景下的表现，本章统计了两个数据集的非零记录占比。NYC-Crimes 数据集的非零比例为 0.1353502，Chicago-Crimes 数据集的非零比例为 0.2637960，说明 NYC-Crimes 具有更高的数据稀疏性。因此，后续实验中除整体性能对比外，本章还重点分析模型在 NYC-Crimes 稀疏区域中的鲁棒性表现。所有实验均在配备 NVIDIA TITAN RTX GPU（24 GB 显存）和 Intel Xeon Gold 5118 CPU 的服务器上完成。为获得较优参数配置，本章采用网格搜索方法对主要超参数进行调节。其中，网络深度在 $\{1, 3, 5, 7\}$ 中选择，隐藏特征维度在 $\{32, 64, 128, 256\}$ 中选择，注意力降维后的维度在 $\{1024, 2048, 4096\}$ 中搜索。卷积核大小设置为 3，批大小设置为 1。受显存限制，训练过程中采用梯度累积策略，累积步数设置为 16。根据验证集上的实验结果，本章最终将网络深度设为 3，隐藏特征维度设为 256，注意力降维维度设为 2048，该配置在训练稳定性和预测精度之间取得了较好平衡。

在对比方法方面，为保证不同章节实验结果之间具有一致性和可比性，本章沿用第三章中介绍的基线模型进行实验比较。所选方法包括传统统计模型 ARIMA、传

统机器学习模型 SVM，以及 ST-ResNet、DCRNN、DeepCrime、STDN、ST-MetaNet、STGCN、GWN、GMAN、AGCRN、MTGNN、STTrans、ST-SHN、DMSTGCN 和 ST-HSL 等具有代表性的深度时空预测模型。其中，ST-HSL 作为面向犯罪预测任务的时空超图自监督学习方法，在稀疏犯罪数据建模方面具有较强代表性，因此仍作为本章的主要强基线模型之一。各基线方法的基本原理已在第三章实验设置部分进行说明，本章不再重复展开。在评价指标方面，本章采用平均绝对误差（MAE）和平均绝对百分比误差（MAPE）作为主要评价指标。二者均为误差类指标，数值越小表示模型预测结果越接近真实值。其中，MAE 用于衡量预测值与真实值之间的平均绝对偏差，MAPE 用于从相对误差角度评估模型预测性能。由于第二章已对相关评价指标进行了详细介绍，本节不再重复展开。

4.3.3 模型性能分析

为验证本章所提出 GLA-STN 模型的预测性能，本章在 NYC-Crimes 和 Chicago-Crimes 两个真实犯罪数据集上与多类基线模型进行对比实验。实验结果如表 4.2 所示，其中 MAE 和 MAPE 均为误差类指标，数值越小表示模型预测结果越接近真实值，相对的模型表现也越好。

从整体结果来看，GLA-STN 在两个数据集的各类犯罪预测任务中均取得了最优或较优的性能表现。与传统统计模型和传统机器学习方法相比，GLA-STN 能够通过深层神经网络结构自动学习犯罪数据中的复杂时空特征，因此在各项指标上均表现出明显优势。与一般深度时空预测模型相比，GLA-STN 通过局部特征提取模块捕捉邻近区域、相邻时间片以及犯罪类型之间的局部依赖关系，并通过全局信息增强模块进一步建模跨区域、跨时间的长距离关联，从而获得更加充分的时空特征表示。进一步地，本章选取性能较强的 ST-HSL 作为主要对比对象。ST-HSL 是一种面向犯罪预测任务的时空超图自监督学习方法，在稀疏犯罪数据建模方面具有较强代表性。与 ST-HSL 相比，GLA-STN 在 NYC-Crimes 数据集上取得了较为显著的性能提升。具体而言，在入室盗窃（Burglary）预测任务中，GLA-STN 相比 ST-HSL 分别降低了 19.4% 的 MAE 和 23.8% 的 MAPE；在盗窃（Larceny）预测任务中，MAE 和 MAPE 分别降低了 7.9% 和 3.8%；在抢劫（Robbery）预测任务中，MAE 和 MAPE 分别降低了 10.8% 和 4.5%；在袭击（Assault）预测任务中，MAE 和 MAPE 分别降低了 11.0% 和 9.2%。总体来看，GLA-STN 在 NYC-Crimes 数据集上相较于 ST-HSL

表 4.2 NYC-Crimes 和 Chicago-Crimes 数据集上的模型性能对比

Table 4.2 Comparison of model performance on the NYC-Crimes and Chicago-Crimes datasets

Models	New York City								Chicago							
	Burglary		Larceny		Robbery		Assault		Theft		Battery		Assault		Damage	
	MAE	MAPE	MAE	MAPE	MAE	MAPE	MAE	MAPE	MAE	MAPE	MAE	MAPE	MAE	MAPE	MAE	MAPE
SVM (2011)	1.1604	0.7653	1.4979	0.6417	1.1278	0.6733	1.1928	0.6964	1.7711	0.5629	1.3493	0.6027	1.0879	0.6560	1.1313	0.5721
ARIMA (2012)	0.8999	0.6363	1.3015	0.6268	0.9558	0.5969	0.9992	0.6198	1.5965	0.5720	1.3212	0.5792	0.8691	0.6044	1.0430	0.6134
ST-ResNet (2017)	0.8680	0.5603	1.1082	0.5478	0.8177	0.5209	0.9645	0.5749	1.3931	0.5488	1.1519	0.5719	0.7679	0.4633	0.9064	0.5018
DCRNN (2018)	0.8176	0.5324	1.0732	0.5492	0.9189	0.5532	0.9692	0.5955	1.3699	0.5770	1.1583	0.5528	0.7639	0.4600	0.8764	0.4756
STGCN (2018)	0.8366	0.5404	1.0692	0.5295	0.9035	0.5441	0.9375	0.5757	1.3628	0.5359	1.1512	0.5761	0.7963	0.4810	0.9068	0.4959
DeepCrime (2018)	0.8227	0.5508	1.0618	0.5351	0.9083	0.5380	0.9222	0.5777	1.3391	0.5430	1.1290	0.5389	0.7737	0.4616	0.9096	0.4960
GWN (2019)	0.7993	0.5235	1.0493	0.5405	0.8681	0.5351	0.8866	0.5646	1.3211	0.5502	1.1331	0.5503	0.7493	0.4580	0.8584	0.4850
STDN (2019)	0.8831	0.5768	1.1442	0.5889	0.9230	0.5649	0.9498	0.5661	1.5303	0.6287	1.2076	0.5791	0.8052	0.4820	0.9169	0.4869
ST-MetaNet (2019)	0.8285	0.5369	1.0697	0.5424	0.9152	0.5766	0.9320	0.5870	1.3369	0.5369	1.1762	0.5748	0.7904	0.4753	0.8907	0.4756
STTrans (2020)	0.8167	0.5592	1.0862	0.5473	0.8848	0.5312	0.9139	0.5655	1.3404	0.5356	1.1466	0.5684	0.7671	0.4499	0.8987	0.4842
GMAN (2020)	0.8652	0.5633	1.0834	0.5340	0.9234	0.5671	0.9338	0.5803	1.3235	0.5307	1.1442	0.5560	0.7852	0.4714	0.8823	0.4838
AGCRN (2020)	0.8260	0.5397	1.0950	0.5404	0.9013	0.5338	0.9063	0.5519	1.3281	0.5304	1.1432	0.5697	0.7669	0.4612	0.8712	0.4859
MTGNN (2020)	0.8429	0.5497	1.0375	0.5237	0.9026	0.5363	0.9256	0.5664	1.3054	0.5378	1.1307	0.5597	0.7571	0.4572	0.8667	0.4859
ST-SHN (2021)	0.8012	0.5198	1.0431	0.5291	0.8777	0.5362	0.9169	0.5682	1.3231	0.5310	1.1348	0.5544	0.7758	0.4574	0.8741	0.4747
DMSTGCN (2021)	0.8376	0.5485	1.0401	0.5464	0.8597	0.5403	0.9306	0.5601	1.3292	0.5291	1.1297	0.5552	0.8058	0.4759	0.8698	0.4877
ST-HSL (2022)	0.7329	0.4788	1.0316	0.5040	0.7912	0.4595	0.8484	0.5029	1.2952	0.4929	1.1016	0.5231	0.6665	0.3996	0.8446	0.4644
GLA-STN (Ours)	0.5911	0.3647	0.9507	0.4848	0.7061	0.4389	0.7551	0.4566	1.2674	0.4816	1.0927	0.5019	0.6373	0.3745	0.7961	0.4217

分别取得了平均 12.3% 的 MAE 提升和 10.3% 的 MAPE 提升。

在 Chicago-Crimes 数据集上, GLA-STN 同样在不同犯罪类型上保持了稳定的预测优势。具体而言, 在盗窃 (Theft) 预测任务中, GLA-STN 相比 ST-HSL 分别降低了 2.1% 的 MAE 和 2.3% 的 MAPE; 在殴打 (Battery) 预测任务中, MAE 和 MAPE 分别降低了 0.8% 和 4.1%; 在袭击 (Assault) 预测任务中, MAE 和 MAPE 分别降低了 4.4% 和 6.3%; 在刑事损害 (Damage) 预测任务中, MAE 和 MAPE 分别降低了 5.7% 和 9.2%。平均来看, GLA-STN 在 Chicago-Crimes 数据集上分别取得了 2.9% 的 MAE 提升和 5.3% 的 MAPE 提升。

为进一步验证 GLA-STN 模型在稀疏犯罪数据场景下的鲁棒性, 本章根据不同区域的犯罪发生密度对测试区域进行划分。其中, 区域犯罪发生密度定义为该区域犯罪时间序列 X_r 中非零记录所占比例。基于该定义, 本章选取犯罪发生密度不高于 0.5 的低犯罪活跃区域, 并进一步划分为 $(0, 0.25]$ 和 $(0.25, 0.5]$ 两个稀疏程度区间, 分别表示高稀疏区域和中等稀疏区域。从图 4.2 可以看出, 在不同稀疏程度区域中, GLA-STN 均取得了优于 ST-HSL 的预测结果。在犯罪发生密度为 $(0, 0.25]$ 的高稀疏区域中, GLA-STN 相比 ST-HSL 分别降低了 31.2% 的 MAE、33.8% 的 MAPE

和 23.7% 的 RMSE；在犯罪发生密度为 $(0.25, 0.5]$ 的中等稀疏区域中，GLA-STN 在 MAE、MAPE 和 RMSE 上分别降低了 24.4%、30.7% 和 14.8%。综合两个稀疏区间来看，GLA-STN 在 MAE、MAPE 和 RMSE 上分别取得了平均 27.8%、32.3% 和 19.3% 的相对性能提升。




图 4.2 不同稀疏程度区域下 ST-HSL 与 GLA-STN 的性能对比

Figure 4.2 Performance comparison between ST-HSL and GLA-STN under different sparsity levels

上述实验结果表明，GLA-STN 在犯罪数据稀疏场景下具有较好的鲁棒性。尤其是在犯罪发生密度较低的区域中，模型仍能够保持较低的预测误差，说明全局信息增强模块能够有效补充局部样本不足带来的信息缺失问题，并缓解稀疏数据导致的预测性能下降。

4.3.4 消融实验分析

为进一步验证 GLA-STN 模型中各关键模块的有效性，本章通过移除模型中的部分核心组件开展消融实验。具体而言，本章分别构建移除局部特征提取模块（Stem CNN）、移除全局信息增强模块（Global Enhance Block）以及移除卷积前馈增强模块（ConvFFN）的模型变体，并与完整 GLA-STN 模型进行对比。通过该实验，可以更加直观地分析不同模块对整体预测性能的贡献。如图 4.3 所示，完整 GLA-STN 模型在 RMSE、MAE 和 MAPE 三个整体评价指标上均取得了最优结果，说明各模块之间能够形成有效互补。其中，移除卷积前馈增强模块后，模型在三个指标上的误差均出现较明显上升，表明该模块不仅能够完成通道维度上的特征映射，还能够通过卷积操作进一步融合局部时空上下文信息，从而增强模型对细粒度犯罪模

式的表达能力。移除全局信息增强模块后，模型性能同样下降，说明跨区域、跨时间全局依赖关系对于提升预测精度具有重要作用。移除局部特征提取模块后，模型误差也有所增加，表明前端局部特征对于捕捉邻近区域、相邻时间片和犯罪类型之间的短期依赖关系具有必要性。




图 4.3 GLA-STN 模型在整体评价指标上的消融实验结果

Figure 4.3 Ablation study results of GLA-STN on overall evaluation metrics

此外，本章进一步分析不同模块在不同犯罪类型中的作用，如图 4.4 所示。对于入室盗窃（Burglary）而言，移除不同模块后模型性能均出现一定程度下降，说明局部建模、全局增强和卷积前馈增强对于该类犯罪预测均具有贡献。对于盗窃（Larceny）而言，移除卷积前馈增强模块后性能下降最为明显，说明该类别样本数量相对较多，模型更需要在特征层面对复杂分布进行进一步整合与校正。对于抢劫（Robbery）和袭击（Assault）等相对稀疏的犯罪类型，移除全局信息增强模块会带来较明显的误差增加，说明在局部观测信息不足的情况下，跨区域和跨时间全局依赖信息能够为预测提供重要补充。进一步地，本章还在不同稀疏程度区域下考察各模块的贡献。实验结果表明，完整 GLA-STN 模型在不同稀疏区域中均保持较优表现，尤其是在高稀疏区域中，全局信息增强模块的作用更加明显。这说明当局部犯罪样本较少时，模型需要借助更大范围内的全局上下文信息来弥补局部观测不足，从而提升稀疏区域中的预测稳定性。

消融实验结果表明，GLA-STN 中的各个模块均对模型性能具有积极作用。局部特征提取模块为模型提供了基础的局部时空表示，全局信息增强模块有效捕捉了长距离依赖关系，卷积前馈增强模块则进一步提升了特征表达和局部上下文融合能力。三者共同作用，使模型能够在整体预测、不同犯罪类型预测以及稀疏区域预测中均保持较好的性能表现。




图 4.4 不同犯罪类型下 GLA-STN 模型的消融实验结果

Figure 4.4 Ablation study results of GLA-STN for different crime types

4.4 本章小结

本章在第三章研究的基础上，进一步围绕深层全局-局部信息交互问题，提出了一种基于全局-局部信息增强的犯罪时空预测模型 GLA-STN。首先通过特征嵌入层、空间-类型卷积和时间-类型卷积提取犯罪数据中的局部时空特征，为后续全局建模提供具有局部归纳偏置的基础表示。在全局信息建模方面，本章引入卷积式位置编码层，将空间位置和时间顺序信息显式融入局部特征表示；随后设计基于低秩投影思想的高效全局自注意力层，在降低注意力计算复杂度的同时捕捉跨区域、跨时间和跨犯罪类型的长距离依赖关系。进一步地，本章通过上下文信息融合模块，对全局特征与局部上下文进行交互融合，并将上述结构封装为可堆叠的全局增强单元，使模型能够逐层整合全局上下文与局部细节信息。

实验结果表明，GLA-STN 在 NYC-Crimes 和 Chicago-Crimes 两个真实犯罪数据集上均优于多种基线模型，并在稀疏区域中表现出较好的鲁棒性。消融实验进一步验证了局部特征提取模块、全局信息增强模块和卷积前馈增强模块的有效性。本章所提出的模型能够兼顾局部细粒度特征感知与深层全局依赖建模，从而提升复杂犯罪时空预测任务的预测精度与稳定性。

第五章 总结与展望

5.1 总结

随着城市化进程的不断推进，城市公共安全治理对犯罪风险预测提出了更高要求。犯罪行为在时间和空间维度上通常呈现出复杂的动态演化特征，不同区域、不同时间点以及不同犯罪类型之间也存在潜在关联关系。与此同时，城市犯罪数据普遍具有稀疏性强、分布不均衡以及局部与全局依赖并存等特点，使得传统统计方法和部分深度学习方法难以充分刻画其复杂时空规律。为提升犯罪预测模型对复杂时空依赖关系的表达能力，本文围绕基于时空注意力机制的犯罪行为建模与预测问题展开研究，重点关注局部时空依赖建模、全局关联关系建模以及稀疏犯罪数据预测等关键问题。为解决上述问题，本文以城市犯罪时空预测任务为研究对象，结合卷积神经网络、注意力机制和深度时空建模方法，提出了两种面向犯罪预测任务的深度学习模型。本文的具体研究工作如下：

1) 针对现有方法难以同时刻画局部时空依赖与全局关联关系的问题，本文提出了一种基于全局-局部调制原型注意力机制的犯罪时空预测模型 **GL-MoPA**。该模型通过嵌入层将原始犯罪计数映射到连续潜在特征空间，以提升原始稀疏数据的特征表达能力；随后利用局部依赖建模模块对时空邻域以及犯罪类型之间的局部交互关系进行联合建模，从而提取细粒度局部时空特征。在全局依赖建模方面，本文引入原型感知注意力机制，将细粒度时空特征聚合为可学习的原型表示，使模型能够在原型层面捕捉跨区域、跨时间的长距离依赖关系。进一步地，本文设计全局-局部信息调制机制，利用局部特征对全局表示进行自适应调整，实现局部细节信息与全局上下文信息的有效融合。针对犯罪数据中大量零值样本造成的预测偏置问题，本文还提出两阶段犯罪预测机制，将犯罪发生概率估计与犯罪强度预测进行解耦，以增强模型在稀疏区域中的预测稳定性。实验结果表明，**GL-MoPA** 在 **NYC-Crimes** 数据集上取得优于多个基线模型的预测性能，并在稀疏犯罪区域表现出较好的鲁棒性。

2) 在上述研究基础上，本文进一步提出了一种基于全局-局部信息增强的犯罪时空预测模型 **GLA-STN**。该模型采用“局部特征提取—全局信息增强—预测输出”的整体结构，通过特征嵌入层、空间-类型卷积和时间-类型卷积提取犯罪数据中的

局部时空特征，为后续全局建模提供具有局部归纳偏置的基础表示。随后，本文引入位置编码，将空间位置和时间顺序信息显式融入特征表示；在全局建模阶段，采用基于低秩投影思想的高效全局自注意力机制，在降低注意力计算复杂度的同时捕捉跨区域、跨时间以及跨犯罪类型的长距离依赖关系。进一步地，本文设计上下文信息融合的卷积前馈增强模块，使全局特征能够与局部上下文信息充分交互，并通过可堆叠的全局增强单元逐层整合深层全局上下文与局部细节特征。实验结果表明，GLA-STN在NYC-Crimes 和 Chicago-Crimes 两个真实犯罪数据集上均取得了较优预测性能，并在不同稀疏程度区域中保持了较好的稳定性。消融实验进一步验证了局部特征提取模块、全局信息增强模块以及卷积前馈增强模块的有效性。

综上，本文围绕城市犯罪预测中的复杂时空依赖建模问题，从原型注意力建模和全局信息增强两个角度开展研究，提出了两种面向犯罪时空预测任务的深度学习模型。实验结果表明，本文方法能够有效融合局部时空特征与全局依赖信息，在一定程度上缓解犯罪数据稀疏性和分布不均衡带来的影响，并提升模型在不同犯罪类型和不同城市数据集上的预测精度与鲁棒性。本文研究为复杂城市犯罪数据的时空建模提供了一种可行思路，也可为公共安全风险预警和警力资源优化配置提供一定的技术参考。

5.2 展望

本文围绕基于时空注意力机制的犯罪行为建模与预测问题开展了研究，并在真实犯罪数据集上验证了所提出模型对于稀疏倾斜犯罪数据集的有效性。虽然本文方法在局部与全局依赖建模、稀疏数据预测以及多类型犯罪预测方面取得了一定效果，但在实际城市犯罪预测场景中，仍存在一些值得进一步研究的问题。未来的研究工作可以从以下几个方面展开：

- 1) 进一步融合多源异构城市数据。本文主要基于历史犯罪记录进行建模，能够从犯罪事件自身的时空分布中学习潜在规律。然而，在真实城市环境中，犯罪行为还可能受到人口流动、交通状况、天气变化、节假日活动、城市功能区分布以及社会经济因素等多种外部因素影响。仅依赖历史犯罪计数数据，可能无法充分反映犯罪发生的复杂诱因。因此，未来可以进一步引入兴趣点数据、人口热力数据、交通流量数据、天气数据和城市环境数据等多源信息，构建更加全面的犯罪预测框架，

从而提升模型对复杂现实场景的适应能力。

2) 进一步增强犯罪预测模型的可解释性。犯罪预测任务与公共安全治理和警务决策密切相关,模型不仅需要具有较高的预测精度,还应能够解释预测结果产生的原因。本文通过原型注意力和全局信息增强机制提升了模型对关键时空依赖关系的建模能力,但对于模型为何在某些区域或时间段给出较高风险预测,仍有进一步解释的空间。未来可以结合注意力可视化、原型区域分析、关键时间片识别和特征贡献度评估等方法,提高模型预测结果的透明和可理解性,更好地服务于实际决策。

3) 推动模型在实际警务应用场景中的落地。犯罪预测模型的最终目标是为城市公共安全治理提供辅助决策支持。未来可以进一步结合实际警务业务流程,将预测结果应用于风险区域识别、巡逻路径规划、警力资源配置和重点时段预警等任务中。同时,在实际部署过程中,还需要综合考虑数据隐私保护、模型公平性、预测误差风险以及系统实时性等问题,以保证犯罪预测技术能够更加安全、可靠地服务于城市治理实践。

城市犯罪预测仍然是一个具有挑战性的复杂时空建模问题。未来随着城市感知数据的不断丰富和深度学习技术的持续发展,融合多源数据、提升跨区域泛化能力、增强模型可解释性并推动实际应用落地,将成为犯罪预测研究的重要发展方向。

参考文献

- [1] WANG T, RUDIN C, WAGNER D, et al. Learning to detect patterns of crime[C]//Joint European Conference on Machine Learning and Knowledge Discovery in Databases. 2013: 515-530.
- [2] COHEN L E, FELSON M. Social change and crime rate trends: A routine activity approach[J]. American Sociological Review, 1979, 44(4): 588-608.
- [3] GARLAND D. Governmentality'and the problem of crime: Foucault, criminology, sociology[J]. Theoretical criminology, 1997, 1(2): 173-214.
- [4] SHAH N, BHAGAT N, SHAH M. Crime forecasting: a machine learning and computer vision approach to crime prediction and prevention[J]. Visual Computing for Industry, Biomedicine, and Art, 2021, 4(1): 9-51.
- [5] ZAVRŠNIK A. Algorithmic justice: Algorithms and big data in criminal justice settings[J]. European Journal of criminology, 2021, 18(5): 623-642.
- [6] WU J, ABRAR S M, AWASTHI N, et al. Enhancing short-term crime prediction with human mobility flows and deep learning architectures[J]. EPJ data science, 2022, 11(1): 53-73.
- [7] TEKIN S F, KOZAT S S. Crime prediction with graph neural networks and multivariate normal distributions[J]. Signal, Image and Video Processing, 2023, 17(4): 1053-1059.
- [8] ZHAO L. Event prediction in the big data era: A systematic survey[J]. ACM Computing Surveys, 2021, 54(5): 1-37.
- [9] HAMDİ A, SHABAN K, ERRADI A, et al. Spatiotemporal data mining: a survey on challenges and open problems[J]. Artificial Intelligence Review, 2021, 55(2): 1441-1488.
- [10] HE J, ZHENG H. Prediction of crime rate in urban neighborhoods based on machine learning[J]. Engineering Applications of Artificial Intelligence, 2021, 106: 104460.

- [11] GUO S, LIN Y, FENG N, et al. Attention based spatial-temporal graph convolutional networks for traffic flow forecasting[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2019: 922-929.
- [12] BOGOMOLOV A, LEPRI B, STAIANO J, et al. Once upon a crime: towards crime prediction from demographics and mobile data[C]//Proceedings of the 16th International Conference on Multimodal Interaction. 2014: 427-434.
- [13] CECCATO V, BRANTINGHAM P. What is the role of architects and urban planners in crime prevention[J]. Security Journal, 2024, 37(3): 489-514.
- [14] BUNNIN F O, SMITH J Q. A bayesian hierarchical model for criminal investigations [J]. Bayesian Analysis, 2021, 16(1): 1-30.
- [15] RODRIGUES A, GONZÁLEZ J A, MATEU J. A conditional machine learning classification approach for spatio-temporal risk assessment of crime data[J]. Stochastic Environmental Research and Risk Assessment, 2023, 37(7): 2815-2828.
- [16] MOHLER G O, SHORT M B, BRANTINGHAM P J, et al. Self-exciting point process modeling of crime[J]. Journal of the American Statistical Association, 2011, 106(493): 100-108.
- [17] 刘绍含. 回归分析在犯罪预测中的应用[J]. 河北法学, 1987(02): 42-48.
- [18] 李其富. 灰色系统模型及其在犯罪预测中的应用[J]. 四川省公安管理干部学院学报, 1996(01): 19-22+65.
- [19] BERK R, SHERMAN L, BARNES G, et al. Forecasting murder within a population of probationers and parolees: a high stakes application of statistical learning[J]. Journal of the Royal Statistical Society Series A: Statistics in Society, 2009, 172(1): 191-211.
- [20] WANG X, GERBER M S, BROWN D E. Automatic crime prediction using events extracted from twitter posts[C]//International Conference on Social Computing, Behavioral-Cultural Modeling, and Prediction. 2012: 231-238.
- [21] AZIZ R M, SHARMA P, HUSSAIN A. Machine learning algorithms for crime prediction under indian penal code[J]. Annals of data Science, 2024, 11(1): 379-410.

- [22] 孙菲菲, 曹卓, 肖晓雷. 基于随机森林的分类器在犯罪预测中的应用研究[J]. 情报杂志, 2014, 33(10): 148-152.
- [23] 陈鹏, 疏学明, 袁宏永, 等. 时空犯罪热点预测模型研究[J]. 系统仿真学报, 2011, 23(09): 1782-1786.
- [24] FENG G, QIN Y, HUANG R, et al. Criminal action graph: a semantic representation model of judgement documents for legal charge prediction[J]. Information Processing & Management, 2023, 60(5): 103421.
- [25] AZEEZ J, ARAVINDHAR D J. Hybrid approach to crime prediction using deep learning[C]//2015 International Conference on Advances in Computing, Communications and Informatics. 2015: 1701-1710.
- [26] 涂伟, 曹劲舟, 高琦丽, 等. 融合多源时空大数据感知城市动态[J]. 武汉大学学报(信息科学版), 2020, 45(12): 1875-1883.
- [27] 夏英, 石枢琦. 面向交通流量预测的多头注意力时空卷积图网络模型[J]. 计算机应用研究, 2023, 40(03): 766-770.
- [28] ZHANG J, ZHENG Y, QI D, et al. DNN-based prediction model for spatio-temporal data[C]//Proceedings of the 24th ACM SIGSPATIAL International Conference on Advances in Geographic Information Systems. 2016: 1-4.
- [29] LIU Z, LIN Y, CAO Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 10012-10022.
- [30] XIE G, SHANGGUAN A, FEI R, et al. Motion trajectory prediction based on a CNN-LSTM sequential model[J]. Science China Information Sciences, 2020, 63(11): 212207-212275.
- [31] JIANG L, XU M, LIU T, et al. Deepvs: A deep learning based video saliency prediction approach[C]//Proceedings of the European Conference on Computer Vision. 2018: 602-617.
- [32] ZHANG Y, LI X, LIU C, et al. Vidtr: Video transformer without convolutions[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 13577-13587.

- [33] GONG D, LEE J, KIM M, et al. Future transformer for long-term action anticipation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 3052-3061.
- [34] NEIMARK D, BAR O, ZOHAR M, et al. Video transformer network[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 3163-3172.
- [35] GIRDHAR R, GRAUMAN K. Anticipative video transformer[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 13505-13515.
- [36] SHI Z, XU X, LIU X, et al. Video frame interpolation transformer[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 17482-17491.
- [37] GU J, HU C, ZHANG T, et al. Vip3d: End-to-end visual trajectory prediction via 3d agent queries[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 5496-5506.
- [38] ARTHUR D, VASSILVITSKII S, et al. k-means++: The advantages of careful seeding[C]//Proceedings of the Eighteenth Annual ACM-SIAM Symposium on Discrete Algorithms. 2007: 1027-1035.
- [39] MCQUEEN J B. Some methods of classification and analysis of multivariate observations[C]//Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability. 1967: 281-297.
- [40] YANG J, PARIKH D, BATRA D. Joint unsupervised learning of deep representations and image clusters[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 5147-5156.
- [41] CARON M, BOJANOWSKI P, JOULIN A, et al. Deep clustering for unsupervised learning of visual features[C]//Proceedings of the European Conference on Computer Vision. 2018: 132-149.
- [42] SHI J, MALIK J. Normalized cuts and image segmentation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2000, 22(8): 888-905.

- [43] NEWMAN M E J. Modularity and community structure in networks[J]. Proceedings of the National Academy of Sciences, 2006, 103(23): 8577-8582.
- [44] DHILLON I S. Co-clustering documents and words using bipartite spectral graph partitioning[C]//Proceedings of the Seventh ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. 2001: 269-274.
- [45] SNELL J, SWERSKY K, ZEMEL R. Prototypical networks for few-shot learning [C]//Advances in Neural Information Processing Systems. 2017: 4077-4087.
- [46] HSU W N, ZHANG Y, GLASS J. Unsupervised learning of disentangled and interpretable representations from sequential data[C]//Advances in Neural Information Processing Systems. 2017: 1878-1888.
- [47] PAN B, DEMIRYUREK U, SHAHABI C. Utilizing real-world transportation data for accurate traffic prediction[C]//2012 IEEE 12th International Conference on Data Mining. 2012: 595-604.
- [48] CHANG C C, LIN C J. LIBSVM: A library for support vector machines[J]. ACM Transactions on Intelligent Systems and Technology, 2011, 2(3): 1-27.
- [49] ZHANG J, ZHENG Y, QI D. Deep spatio-temporal residual networks for citywide crowd flows prediction[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2017: 1655-1661.
- [50] HUANG C, ZHANG J, ZHENG Y, et al. Deepcrime: Attentive hierarchical recurrent networks for crime prediction[C]//Proceedings of the 27th ACM International Conference on Information and Knowledge Management. 2018: 1423-1432.
- [51] YAO H, TANG X, WEI H, et al. Revisiting spatial-temporal similarity: A deep learning framework for traffic prediction[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2019: 5668-5675.
- [52] PAN Z, LIANG Y, WANG W, et al. Urban traffic prediction from spatio-temporal data using deep meta learning[C]//Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. 2019: 1720-1730.

- [53] LI Y, YU R, SHAHABI C, et al. Diffusion convolutional recurrent neural network: Data-driven traffic forecasting[C]//International Conference on Learning Representations. 2018.
- [54] YU B, YIN H, ZHU Z. Spatio-temporal graph convolutional networks: A deep learning framework for traffic forecasting[C]//Proceedings of the Twenty-Seventh International Joint Conference on Artificial Intelligence. 2018: 3634-3640.
- [55] WU Z, PAN S, LONG G, et al. Graph wavenet for deep spatial-temporal graph modeling[C]//Proceedings of the Twenty-Eighth International Joint Conference on Artificial Intelligence. 2019: 1907-1913.
- [56] ZHENG C, FAN X, WANG C, et al. Gman: A graph multi-attention network for traffic prediction[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2020: 1234-1241.
- [57] BAI L, YAO L, LI C, et al. Adaptive graph convolutional recurrent network for traffic forecasting[C]//Advances in Neural Information Processing Systems. 2020: 17804-17815.
- [58] WU Z, PAN S, LONG G, et al. Connecting the dots: Multivariate time series forecasting with graph neural networks[C]//Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. 2020: 753-763.
- [59] WU X, HUANG C, ZHANG C, et al. Hierarchically structured transformer networks for fine-grained spatial event forecasting[C]//Proceedings of The Web Conference 2020. 2020: 2320-2330.
- [60] XIA L, HUANG C, XU Y, et al. Spatial-temporal sequential hypergraph network for crime prediction with dynamic multiplex relation learning[C]//Proceedings of the Thirtieth International Joint Conference on Artificial Intelligence. 2021: 1631-1637.
- [61] HAN L, DU B, SUN L, et al. Dynamic and multi-faceted spatio-temporal deep learning for traffic speed forecasting[C]//Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery & Data Mining. 2021: 547-555.

- [62] LI Z, HUANG C, XIA L, et al. Spatial-temporal hypergraph self-supervised learning for crime prediction[C]//2022 IEEE 38th International Conference on Data Engineering. 2022: 2984-2996.
- [63] WANG S, LI B Z, KHABSA M, et al. Linformer: Self-attention with linear complexity [A]. 2020. arXiv: 2006.04768.

攻读专业硕士学位期间取得的研究成果

一、论文

[1] Zhao Y, Zhou Y, Chen Y, et al. Global-Local Modulated Prototype Attention Network for Spatio-Temporal Crime Prediction[J]. Applied Sciences, 2026, 16(5): 2572. (SCI期刊, 第一作者)

[2] Gong Z, Shan K, Zhao Y, et al. Real-time algal bloom detection technique: a zero-shot approach using DINOv2 and HSV filtering[C]//Proceedings of the 2024 12th International Conference on Communications and Broadband Networking. 2024: 102-107. (EI会议, 共同一作)

致 谢

时光荏苒，硕士研究生阶段的学习与科研工作即将结束。回顾这段求学经历，从课程学习、科研训练到论文撰写，每一步成长都离不开老师、同学、家人和朋友的关心与帮助。在论文完成之际，谨向所有给予我指导、支持和鼓励的人表示诚挚的感谢。

首先，我要衷心感谢我的导师吴汉舟老师。在硕士研究生学习期间，不仅在学术科研方面给予了我悉心指导。导师严谨的治学态度、扎实的学术功底和认真负责的工作作风，也使我受益匪浅。在课题研究过程中，导师不仅帮助我明确研究方向，也在我遇到困难和瓶颈时给予耐心指导和鼓励，使我能够不断完善研究内容并顺利完成论文工作。在此，向导师致以最诚挚的敬意和感谢。

同时，感谢实验室的各位同学以及一路陪伴和支持我的朋友们。在研究生学习、课题讨论、实验分析和论文修改过程中，大家给予了我许多帮助与建议，使我受益良多；在学习和生活遇到困难时，你们的理解、鼓励与陪伴也让我能够以更加积极的心态面对挑战。与大家共同学习、相互支持和不断进步的经历，是我研究生阶段十分宝贵而温暖的回忆。

感谢我的家人一直以来对我的理解、支持与鼓励。无论是在学习还是生活中，家人的关心始终是我不断前进的重要动力。正是因为有你们的支持，我才能够更加坚定地完成研究生阶段的学习任务和论文写作。

最后，感谢所有在论文研究和写作过程中给予我帮助的人。硕士阶段的学习经历让我在专业能力、科研思维和个人成长方面都收获良多。未来我将继续保持认真踏实的态度，不断学习和进步。

谨以此文，向所有关心、帮助和支持我的人表示衷心感谢。

赵宇辰

上海大学

2026 年 3 月 15 日